

スパース回帰 (5章)


杉山将・本多淳也

sugi@k.u-tokyo.ac.jp, jhonda@k.u-tokyo.ac.jp

<http://www.ms.k.u-tokyo.ac.jp>

回帰 = 関数近似

2



$f(x)$: 学習したい真の関数

$\hat{f}(x)$: 学習結果の関数

$\{(x_i, y_i)\}_{i=1}^n$: 訓練標本

$y_i = f(x_i) (+\text{noise})$

訓練標本から真の関数にできるだけ近い関数を求める

パラメータに関する線形モデル 3

■ 線形モデル:
$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^b \theta_j \phi_j(\mathbf{x})$$



$\{\phi_j(\mathbf{x})\}_{j=1}^b$
: 基底関数

■ カーネルモデル:

ガウスカーネル

$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^n \theta_j K(\mathbf{x}, \mathbf{x}_j)$$


$$K(\mathbf{x}, \mathbf{c}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2h^2}\right)$$



最小二乗回帰

- 訓練出力との二乗誤差を最小にする:

$$\min_{\theta} \sum_{i=1}^n \left(f_{\theta}(x_i) - y_i \right)^2$$



正則化

$$\min_{\boldsymbol{\theta}} \left[\underbrace{\frac{1}{2} \sum_{i=1}^n \left(f_{\boldsymbol{\theta}}(\boldsymbol{x}_i) - y_i \right)^2}_{\text{訓練出力に対する適合の良さ}} + \underbrace{\frac{\lambda}{2} \|\boldsymbol{\theta}\|^2}_{\text{パラメータの値が大きくなり過ぎることに対する罰則 (正則化)}} \right]$$

訓練出力に
対する適合
の良さ


パラメータの値が
大きくなり過ぎる
ことに対する罰則
(正則化)

- 訓練出力に対する適合のよさとパラメータの値の大きさをバランスよく小さくし, 過適合を避ける

交差確認によるモデル選択

6

- 訓練標本 $\mathcal{Z} = \{(x_i, y_i)\}_{i=1}^n$ を k 分割する: $\{\mathcal{Z}_i\}_{i=1}^k$
- \mathcal{Z}_i 以外を使って関数を学習する
- 残った \mathcal{Z}_i を使ってテスト誤差を確認する
- これを全ての組み合わせに対して繰り返し、平均を出力する



モデルのスパース性

7

- パラメータ数が多いと推定値の計算が大変

- 例えばカーネルモデルでは,

$$\text{パラメータ数} = \text{訓練標本数}$$

なので訓練標本数が多いとき計算が大変

$$f_{\theta}(\boldsymbol{x}) = \sum_{j=1}^n \theta_j K(\boldsymbol{x}, \boldsymbol{x}_j)$$

- 多くのパラメータ値がゼロになれば,
出力値の計算が簡単になり, 解釈性も向上

■ ナイーブな方法1:

- あらかじめいくつかのパラメータを使用しないことにする
- パラメータが d 個ある時, 選び方は 2^d 通り
- d が大きい時はとても網羅しきれない

■ ナイーブな方法2:

- ℓ_2 -正則化回帰で得られたパラメータのうち, 絶対値の小さいものをゼロに丸めてしまう
- 丸め誤差が発生する

講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張

ℓ_1 -制約付き最小二乗回帰


10

■ モデルを ℓ_1 -超球に限定する



$$\min_{\boldsymbol{\theta}} \frac{1}{2} \sum_{i=1}^n \left(f_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i \right)^2 \quad \text{subject to } \|\boldsymbol{\theta}\|_1 \leq R$$

$$R \geq 0$$

$$\|\boldsymbol{\theta}\|_1 = \sum_{j=1}^b |\theta_j|$$





ℓ_2 -制約付き
最小二乗回帰



ℓ_1 -制約付き
最小二乗回帰

なぜスパースな解が得られるか？¹¹


- 解が軸の上に乗ることが多い



- **スパース回帰**あるいは **LASSO** (Least Absolute Shrinkage and Selection Operator) と呼んだりする

なぜスパースな解が得られるか？¹²

- 両方の変数が本質的に必要な場合は軸の上に乗らない



例

■ ガウスカーネルモデル:

解の計算法
は後ほど


$$f_{\theta}(x) = \sum_{j=1}^n \theta_j K(x, x_j)$$

$$K(x, c) = \exp\left(-\frac{\|x - c\|^2}{2h^2}\right)$$

通常の最小二乗回帰

ℓ_2 -制約付き

ℓ_1 -制約付き



■ ℓ_1 -制約の結果は ℓ_2 -制約と見た目は大体同じ

■ しかし, ℓ_1 -制約は50個のパラメータのうち38個が0


特徴選択

■ 入力に関する線形モデル

$$f_{\theta}(x) = \theta^{\top} x$$

$$x = (x^{(1)}, \dots, x^{(d)})^{\top}$$

に対してスパース学習を行なうと, いくつかの入力変数が使われなくなる.



予測に必要な特徴が
自動的に選択される

■ 例: 重要な遺伝子の自動選択

- 通常は 2^d の組み合わせを調べる必要があるが, スパース学習では λ だけを決めればよい.

講義の流れ

1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張




解の求め方

■ 等価な表現:

$$\hat{\theta} = \operatorname{argmin}_{\theta} \left[\frac{1}{2} \sum_{i=1}^n \left(f_{\theta}(\mathbf{x}_i) - y_i \right)^2 + \lambda \sum_{j=1}^b |\theta_j| \right]$$

$\lambda (\geq 0)$: R から決まる定数


- 実際には R でなく λ を直接指定すればよい.
- しかし, 絶対値は原点で微分できないため, 上記の最適化問題は簡単には解けない





近似的勾配法

17

■ $\theta \leftarrow \theta - \varepsilon \nabla J(\theta)$



■ 絶対値の微分を近似する



■ しかし、多くの解がゼロになるため、実際には不安定でうまくいかない

交互方向乗数法

■ 最適化問題: $\min_{\theta, z} [f(\theta) + g(z)]$

subject to $A\theta + Bz = c$

■ 拡張ラグランジュ関数:

$$L(\theta, z, u) = f(\theta) + g(z) + u^\top (A\theta + Bz - c) + \frac{1}{2} \|A\theta + Bz - c\|^2$$

■ 解の更新式:

- $\theta^{(k+1)} = \operatorname{argmin}_{\theta} L(\theta, z^{(k)}, u^{(k)})$

- $z^{(k+1)} = \operatorname{argmin}_z L(\theta^{(k+1)}, z, u^{(k)})$

- $u^{(k+1)} = u^{(k)} + A\theta^{(k+1)} + Bz^{(k+1)} - c$

交互方向乗数法

■ 最適化問題: $\min_{\theta, z} [f(\theta) + g(z)]$

subject to $A\theta + Bz = c$

■ 拡張ラグランジュ関数:

$$L(\theta, z, u) = f(\theta) + g(z) + u^\top (A\theta + Bz - c)$$

θ と z が動きすぎると
大きくなる

$$+ \frac{1}{2} \|A\theta + Bz - c\|^2$$

- $\theta^{(k+1)} = \operatorname{argmin}_{\theta} L(\theta, z^{(k)}, u^{(k)})$
- $z^{(k+1)} = \operatorname{argmin}_z L(\theta^{(k+1)}, z, u^{(k)})$
- $u^{(k+1)} = u^{(k)} + A\theta^{(k+1)} + Bz^{(k+1)} - c$

交互方向乗数法

■ 最適化問題: $\min_{\theta, z} [f(\theta) + g(z)]$

subject to $A\theta + Bz = c$

■ 拡張ラグランジュ関数:

$$L(\theta, z, u) = f(\theta) + g(z) + u^\top (A\theta + Bz - c) + \frac{1}{2} \|A\theta + Bz - c\|^2$$

■ 解の更新式:

- $\theta^{(k+1)} = \arg\min_{\theta} [f(\theta) + u^{(k)\top} (A\theta + Bz^{(k+1)} - c) + \frac{1}{2} \|A\theta + Bz^{(k+1)} - c\|^2]$
- $z^{(k+1)} = \arg\min_z [g(z) + u^{(k)\top} (A\theta^{(k+1)} + Bz - c) + \frac{1}{2} \|A\theta^{(k+1)} + Bz - c\|^2]$
- $u^{(k+1)} = u^{(k)} + A\theta^{(k+1)} + Bz^{(k+1)} - c$

等式制約を外れた方向へ
罰則を増やす

■ 線形モデル $f_{\boldsymbol{\theta}}(\boldsymbol{x}) = \sum_{j=1}^b \theta_j \phi_j(\boldsymbol{x})$ における

ℓ_1 -正則化最小二乗法の目的関数:

$$\min_{\boldsymbol{\theta}} \left[\frac{1}{2} \|\boldsymbol{\Phi} \boldsymbol{\theta} - \boldsymbol{y}\|^2 + \lambda \|\boldsymbol{\theta}\|_1 \right]$$

$$\boldsymbol{\Phi} = \begin{pmatrix} \phi_1(\boldsymbol{x}_1) & \cdots & \phi_b(\boldsymbol{x}_1) \\ \vdots & \ddots & \vdots \\ \phi_1(\boldsymbol{x}_n) & \cdots & \phi_b(\boldsymbol{x}_n) \end{pmatrix}$$

■ 線形モデル $f_{\boldsymbol{\theta}}(\boldsymbol{x}) = \sum_{j=1}^b \theta_j \phi_j(\boldsymbol{x})$ における

ℓ_1 -正則化最小二乗法の目的関数:

$$\min_{\boldsymbol{\theta}} \left[\frac{1}{2} \|\boldsymbol{\Phi}\boldsymbol{\theta} - \boldsymbol{y}\|^2 + \lambda \|\boldsymbol{\theta}\|_1 \right]$$

■ これは以下と等価

$$\min_{\boldsymbol{\theta}, \boldsymbol{z}} \left[\frac{1}{2} \|\boldsymbol{\Phi}\boldsymbol{\theta} - \boldsymbol{y}\|^2 + \lambda \|\boldsymbol{z}\|_1 \right] \quad \text{subject to } \boldsymbol{\theta} = \boldsymbol{z}$$

■ 解の更新式:


- $\theta^{(k+1)} = \operatorname{argmin}_{\theta} L(\theta, z^{(k)}, u^{(k)})$
- $z^{(k+1)} = \operatorname{argmin}_z L(\theta^{(k+1)}, z, u^{(k)})$
- $u^{(k+1)} = u^{(k)} + A\theta^{(k+1)} + Bz^{(k+1)} - c$

$$L(\theta, z, u) = f(\theta) + g(z) + u^{\top} (A\theta + Bz - c) + \|A\theta + Bz - c\|^2 / 2$$

- $f(\theta) = \|\Phi\theta - y\|^2$, $g(z) = \lambda\|z\|_1$, $A = -B = I$
 $c = 0$ に対して θ と u の更新式を導出せよ

解答＋宿題

■ $\frac{\partial L}{\partial \theta} = \Phi^\top (\Phi \theta - y) + u + \theta - z = 0$



$$\theta^{(k+1)} = \operatorname{argmin}_{\theta} L(\theta, z^{(k)}, u^{(k)})$$

$$= (\Phi^\top \Phi + I)^{-1} (\Phi^\top y + z^{(k)} - u^{(k)})$$

■ z についての更新式 (証明は宿題):

$$z^{(k+1)} = \operatorname{argmin}_z L(\theta^{(k+1)}, z, u^{(k)})$$

$$= \max(\mathbf{0}, \theta^{(k+1)} + u^{(k)} - \lambda \mathbf{1})$$

$$+ \min(\mathbf{0}, \theta^{(k+1)} + u^{(k)} + \lambda \mathbf{1})$$

要素毎の
最大・最小

■ また, $u^{(k+1)} = u^{(k)} + \theta^{(k+1)} - z^{(k+1)}$



線形モデルを用いた ℓ_1 -正則化最小二乗法に対する 交互方向乗数法

■ 適当な初期値から, 以下の更新を繰り返す:

- $\theta \longleftarrow (\Phi^\top \Phi + I)^{-1} (\Phi^\top y + z - u)$
- $z \longleftarrow \max(\mathbf{0}, \theta + u - \lambda \mathbf{1})$
 $\quad - \max(\mathbf{0}, -\theta - u - \lambda \mathbf{1})$
- $u \longleftarrow u + \theta - z$

実行例

$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^n \theta_j \exp \left(-\frac{\|\mathbf{x} - \mathbf{x}_j\|^2}{2h^2} \right)$$



- ℓ_1 -制約の結果は ℓ_2 -制約と見た目は大体同じ
- しかし, ℓ_1 -制約は50個のパラメータのうち38個が0

講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張
 - A) オンライン学習
 - B) 一般化 ℓ_1 -ノルム
 - C) ℓ_p -ノルム
 - D) $\ell_1 + \ell_2$ -ノルム
 - E) $\ell_{1,2}$ -ノルム
 - F) トレースノルム

確率的勾配法によるオンライン学習²⁸ (最小二乗法)

$$\min_{\theta} \frac{1}{2} \sum_{i=1}^n \left(f_{\theta}(x_i) - y_i \right)^2$$

$$f_{\theta}(x) = \sum_{j=1}^b \theta_j \phi_j(x)$$

1. パラメータ θ を適当に初期化
2. 標本 (x, y) をランダムに選び, 勾配を少し降下

$$\theta \leftarrow \theta - \varepsilon \frac{\partial}{\partial \theta} \frac{(f_{\theta}(x) - y)^2}{2}$$

$$= \theta - \varepsilon \phi(x) \left(\theta^{\top} \phi(x) - y \right)$$

ステップ幅

$$\varepsilon > 0$$

3. 収束するまで 2. を繰り返す

■ どうやって ℓ_1 -制約条件を満たすか？

$$\min_{\theta} \frac{1}{2} \sum_{i=1}^n \left(f_{\theta}(\mathbf{x}_i) - y_i \right)^2 + \lambda \sum_{j=1}^b |\theta_j|$$

$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^b \theta_j \phi_j(\mathbf{x})$$

1. パラメータ θ を適当に初期化
2. 標本 (\mathbf{x}, y) をランダムに選び, 勾配を少し降下

$$\theta \leftarrow \theta - \varepsilon \phi(\mathbf{x}) \left(\theta^{\top} \phi(\mathbf{x}) - y \right)$$

ステップ幅

$$\varepsilon > 0$$

3. 解をスパースにする:


$$\forall j = 1, \dots, b, \quad \theta_j \leftarrow \begin{cases} \max(0, \theta_j - \lambda \varepsilon) & (\theta_j > 0), \\ \min(0, \theta_j + \lambda \varepsilon) & (\theta_j \leq 0). \end{cases}$$

4. 収束するまで 2. を繰り返す

スパース化のイメージ

$$\theta_j \leftarrow \begin{cases} \max(0, \theta_j - \lambda\varepsilon) & (\theta_j > 0), \\ \min(0, \theta_j + \lambda\varepsilon) & (\theta_j \leq 0). \end{cases}$$

$$\max(0, \theta_j - \lambda\varepsilon) + \min(0, \theta_j + \lambda\varepsilon)$$



- 正則化により原点に引き寄せられる

講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張
 - A) オンライン学習
 - B) 一般化 ℓ_1 -ノルム
 - C) ℓ_p -ノルム
 - D) $\ell_1 + \ell_2$ -ノルム
 - E) $\ell_{1,2}$ -ノルム
 - F) トレースノルム

一般化 ℓ_1 -ノルム

32

$$\|\mathbf{F}\boldsymbol{\theta}\|_1 = \sum_j \left| \sum_{j'} F_{j,j'} \theta_{j'} \right|$$

■ 例: 差分

$$\sum_j |\theta_{j+1} - \theta_j|$$

$$F_{j,j'} = \begin{cases} 1 & (j' = j + 1) \\ -1 & (j' = j) \\ 0 & (\text{otherwise}) \end{cases}$$


一般化 ℓ_1 -制約付き最小二乗回帰³³

$$\min_{\boldsymbol{\theta}} \frac{1}{2} \sum_{i=1}^n \left(f_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i \right)^2 \quad \text{subject to } \|\mathbf{F}\boldsymbol{\theta}\|_1 \leq R$$

$$R \geq 0$$


■ 例: 全変動ノイズ除去

$$\min_{\boldsymbol{\theta}} \frac{1}{2} \|\boldsymbol{\theta} - \mathbf{y}\|^2 \quad \text{subject to } \sum_j |\theta_{j+1} - \theta_j| \leq R$$



$$F_{j,j'} = \begin{cases} 1 & (j' = j + 1) \\ -1 & (j' = j) \\ 0 & (\text{otherwise}) \end{cases}$$



講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張
 - A) オンライン学習
 - B) 一般化 ℓ_1 -ノルム
 - C) ℓ_p -ノルム
 - D) $\ell_1 + \ell_2$ -ノルム
 - E) $\ell_{1,2}$ -ノルム
 - F) トレースノルム

ℓ_p -ノルム

$$\|\boldsymbol{\theta}\|_p = \left(\sum_{j=1}^b |\theta_j|^p \right)^{\frac{1}{p}}$$



$$p = 0$$

$$\|\boldsymbol{\theta}\|_0 = \# \text{ non-zero elements}$$

$$p = \infty$$

$$\|\boldsymbol{\theta}\|_\infty = \max \{ |\theta_1|, \dots, |\theta_b| \}$$

ℓ_p -制約付き最小二乗回帰


36

■ モデルを ℓ_p -超球に限定する

$$p \geq 0$$

$$\min_{\boldsymbol{\theta}} \frac{1}{2} \sum_{i=1}^n \left(f_{\boldsymbol{\theta}}(\mathbf{x}_i) - y_i \right)^2 \quad \text{subject to } \|\boldsymbol{\theta}\|_p \leq R$$

$$R \geq 0$$




$$\|\boldsymbol{\theta}\|_p = \left(\sum_{j=1}^b |\theta_j|^p \right)^{\frac{1}{p}}$$


ℓ_p -制約付き最小二乗回帰

37

- 解がスパースになる: $0 \leq p \leq 1$
- 最適化問題が凸: $p \geq 1$
(大域的最適解が容易に求まる)
- 両方を満たすのは $p = 1$ のみ!



講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張
 - A) オンライン学習
 - B) 一般化 ℓ_1 -ノルム
 - C) ℓ_p -ノルム
 - D) $\ell_1 + \ell_2$ -ノルム
 - E) $\ell_{1,2}$ -ノルム
 - F) トレースノルム

ℓ_1 -制約付き最小二乗回帰の問題点³⁹

$$\min_{\theta} \frac{1}{2} \sum_{i=1}^n \left(\sum_{j=1}^b \theta_j \phi_j(\mathbf{x}_i) - y_i \right)^2 \quad \text{subject to} \quad \sum_{j=1}^b |\theta_j| \leq R$$

- 非ゼロのパラメータ数は n 以下 ($b > n$ だと不便)
 - 理由: 誤差ベクトル $\Phi\theta - \mathbf{y}$ における Φ が横長行列
- いくつかの基底関数 $\{\phi_j(\mathbf{x})\}_{j=1}^b$ が似ている時, それらの一つしか選ばれない
- $b < n$ の時, ℓ_2 -制約付き最小二乗回帰より性能がやや劣ると言われている



$\ell_1 + \ell_2$ -制約付き最小二乗回帰

40

$$(1 - \tau) \sum_{j=1}^b |\theta_j| + \tau \sum_{j=1}^b \theta_j^2 \leq R$$

$$0 \leq \tau < 1$$

■ $\ell_{1.4}$ -球と似ているが, $\ell_1 + \ell_2$ -球は尖っている



講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張
 - A) オンライン学習
 - B) 一般化 ℓ_1 -ノルム
 - C) ℓ_p -ノルム
 - D) $\ell_1 + \ell_2$ -ノルム
 - E) $\ell_{1,2}$ -ノルム
 - F) トレースノルム

$\ell_{1,2}$ -ノルム

- 設定: 似た性質の変数グループがあるが, それらが役に立つかはわからない
- パラメータ $\theta = (\theta_1, \dots, \theta_b)^\top$ が


$$\theta = (\theta^{(1)\top}, \dots, \theta^{(t)\top})^\top \quad \theta^{(j)} \in \mathbb{R}^{b_j}$$

というグループ構造を持っているとき,


$$\|\theta\|_{1,2} = \sum_{j=1}^t \|\theta^{(j)}\|_2$$

を $\ell_{1,2}$ -ノルムとよび, このようなノルムで正則化することをグループ正則化という

- 3次元の ℓ_2 -ノルムと ℓ_1 -ノルムの制約条件は、以下のように図示できる。




$$\sqrt{\theta_1^2 + \theta_2^2 + \theta_3^2} \leq R$$



$$\sqrt{\theta_1^2} + \sqrt{\theta_2^2} + \sqrt{\theta_3^2} \leq R$$

- 同様に以下の $\ell_{1,2}$ -ノルムを図示し、どのようなスパース解が得られるか説明せよ

$$\sqrt{\theta_1^2 + \theta_2^2} + \sqrt{\theta_3^2} \leq R$$



■ グループごとにスパースな解が得られる.

$$\sum_{j=1}^t \|\boldsymbol{\theta}^{(j)}\| \leq R$$

講義の流れ



1. ℓ_1 -制約付き最小二乗回帰
2. 解の計算法
3. 様々な拡張
 - A) オンライン学習
 - B) 一般化 ℓ_1 -ノルム
 - C) ℓ_p -ノルム
 - D) $\ell_1 + \ell_2$ -ノルム
 - E) $\ell_{1,2}$ -ノルム
 - F) トレースノルム

行列データの回帰

■ 行列データ: $\{(\mathbf{X}_i, y_i) \mid \mathbf{X}_i \in \mathbb{R}^{d_1 \times d_2}, y_i \in \mathbb{R}\}_{i=1}^n$

- 例えば画像や時系列データが入力

■ 行列回帰モデル:

$$f_{\Theta}(\mathbf{X}) = \text{tr}(\Theta^{\top} \mathbf{X}) = \sum_{j_1=1}^{d_1} \sum_{j_2=1}^{d_2} \theta_{j_1 j_2} (X)_{j_1 j_2}$$

- これそのものは、ベクトル化した線形モデルと等価:

$$f_{\Theta}(\mathbf{X}) = \text{vec}(\Theta)^{\top} \text{vec}(\mathbf{X})$$

- ℓ_1 -ノルムや ℓ_2 -ノルムで正則化しても、
行列構造を生かせない

■ 行列 $\Theta \in \mathbb{R}^{d_1 \times d_2}$ に対するトレースノルム:

$$\|\Theta\|_{\text{tr}} = \sum_{k=1}^{\min(d_1, d_2)} \sigma_k$$

$\sigma_k \geq 0$: 行列 Θ の特異値

- 特異値: $\Theta^\top \Theta$ の固有値の平方根
(正方行列なら Θ の固有値の絶対値)
 - トレースノルム: 特異値に対する ℓ_1 -ノルム
- 行列のランクは特異値の非ゼロ要素の数に等しい

トレースノルム制約付き 最小二乗回帰

$$\min_{\Theta \in \mathbb{R}^{d_1 \times d_2}} \frac{1}{2} \sum_{i=1}^n \left(y_i - \text{tr} \left(\Theta^\top \mathbf{X}_i \right) \right)^2 \quad \text{subject to } \|\Theta\|_{\text{tr}} \leq R$$

- トレースノルム制約は,
特異値に対する ℓ_1 -ノルム制約
 - 特異値がスパースになる
 - 行列 Θ が**低ランク**になる！

- 推薦システムにおいて未知の評価を補完したい

	映画1	映画2	映画3	映画4	...
ユーザ1	1	4	*	*	
ユーザ2	*	3	5	2	
ユーザ3	2	*	4	3	
⋮					

- 仮定: 各ユーザの評価 $(X_{i,1}, X_{i,2}, \dots, X_{i,d_2})$ は m 人の仮想ユーザの評価 $(B_{k,1}, B_{k,2}, \dots, B_{k,d_2})$ の線形結合で近似可能 (=低ランク表現可能)

$$X_{i,\cdot} = \sum_{k=1}^m A_{i,k} B_{k,\cdot}$$

$$\begin{matrix} d_1 \\ \boxed{\mathbf{X}} \\ d_2 \end{matrix} = \begin{matrix} \boxed{\mathbf{A}} \\ m \end{matrix} \begin{matrix} \boxed{\mathbf{B}} \end{matrix}$$

- トレースノルム正則化により補完が可能

- ℓ_1 -正則化学習により解をスパースにする
- 解析的に解は求まらない
- スパース回帰の学習アルゴリズムは盛んに研究されており, 最新の手法を用いれば,
 ℓ_2 -正則化学習よりも高速に解ける
 - ゼロを初期値として, 非零になる要素を見つけながら学習すれば, 最終的に零になる要素をほぼ見ることなく学習できる

次回の予告

■ ロバスト回帰(6章)



■ 次式を証明せよ

$$\operatorname{argmin}_z T(z) = \max(0, \theta + u - \lambda) + \min(0, \theta + u + \lambda)$$

(この式はソフト閾値処理とよばれる)

$$\lambda \geq 0$$

$$T(z) = \lambda|z| + u(\theta - z) + \frac{1}{2}(\theta - z)^2$$

■ ガウスカーネルモデル

$$f_{\theta}(x) = \sum_{j=1}^n \theta_j K(x, x_j)$$

$$K(x, c) = \exp \left(-\frac{\|x - c'\|^2}{2h^2} \right)$$

に対して、スパース回帰の交互方向乗数法による反復式を求め、適当なデータとモデル（例えば前回の三角多項式基底による回帰）に対してスパース回帰を実行せよ