

# 確率的分類(10章)と 系列データの分類(11章)

杉山将・本多淳也


sugi@k.u-tokyo.ac.jp, jhonda@k.u-tokyo.ac.jp

<http://www.ms.k.u-tokyo.ac.jp>

# 2クラスの分類問題

- ラベル付き訓練データ:  $\{(x_i, y_i)\}_{i=1}^n$ 
  - 入力  $x$  は  $d$  次元の実ベクトル  $x \in \mathbb{R}^d$
  - 出力  $y$  は2値のクラスラベル  $y \in \{+1, -1\}$

クラス +1



分離境界


クラス-1

- クラス間の分離境界を求めたい

# 2クラスの分類問題

3

■ 2クラス分類問題は2値関数の近似問題と等価：



■ 回帰学習法が分類にも使える！

# パラメータに関する線形モデル 4

■ 線形モデル: 
$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^b \theta_j \phi_j(\mathbf{x})$$


$\{\phi_j(\mathbf{x})\}_{j=1}^b$   
: 基底関数

■ カーネルモデル:

ガウスカーネル

$$f_{\theta}(\mathbf{x}) = \sum_{j=1}^n \theta_j K(\mathbf{x}, \mathbf{x}_j)$$

$$K(\mathbf{x}, \mathbf{c}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2h^2}\right)$$



# 回帰学習による分類

## ■ パラメータを正則化最小二乗回帰で学習

$$\hat{\boldsymbol{\theta}} = \underset{\boldsymbol{\theta}}{\operatorname{argmin}} \left[ \frac{1}{2} \sum_{i=1}^n \left( f_{\boldsymbol{\theta}}(\boldsymbol{x}_i) - y_i \right)^2 + \frac{\lambda}{2} \|\boldsymbol{\theta}\|^2 \right]$$

$\lambda (\geq 0)$ : 正則化パラメータ

## ■ テストパターンの分類:

$$\hat{y} = \operatorname{sign} \left( f_{\hat{\boldsymbol{\theta}}}(\boldsymbol{x}) \right) = \begin{cases} +1 & (f_{\hat{\boldsymbol{\theta}}}(\boldsymbol{x}) > 0) \\ 0 & (f_{\hat{\boldsymbol{\theta}}}(\boldsymbol{x}) = 0) \\ -1 & (f_{\hat{\boldsymbol{\theta}}}(\boldsymbol{x}) < 0) \end{cases}$$

# 0/1-損失関数とマージン

- 分類問題では、学習した関数の符号だけが必要

$$\hat{y} = \text{sign} (f_{\hat{\theta}}(x))$$

- $\ell_2$ -損失でなく, **0/1-損失**の方が自然


$$J_{0/1}(\theta) = \frac{1}{2} \sum_{i=1}^n (1 - \text{sign} (m_i))$$

$$m_i = f_{\theta}(x_i)y_i$$

マージン


- $J_{0/1}(\theta)$  は**誤分類標本数**に相当

- 分類の損失としては理想的
- しかし傾きを持たない離散的な関数
- 0/1-損失の最小化はNP困難



# 代理損失

■ 分類には様々な代理損失が用いられる



# 講義の流れ



## 1. 確率的分類(10章)

- A) ロジスティック回帰
- B) 確率的勾配法
- C) ロジスティック損失最小化
- D) 二乗誤差最小化

## 2. 系列データの分類(11章)



# 確率的分類

- これまで, 学習した関数の符号

$$\hat{y} = \text{sign} (f_{\hat{\theta}}(x))$$

によって分類を行う手法を紹介してきた

- クラス事後確率  $p(y = \hat{y}|x)$  の学習に基づく分類:

$$\hat{y} = \underset{y=1,\dots,c}{\operatorname{argmax}} p(y|x)$$

- クラス予測に対する信頼度<sup>信頼度</sup>が得られる  
(信頼度が低い場合は自動分類をあきらめる等)
- 多クラス分類<sup>多クラス分類</sup>が自然に行える

# 講義の流れ



## 1. 確率的分類(10章)

- A) ロジスティック回帰
- B) 確率的勾配法
- C) ロジスティック損失最小化
- D) 二乗誤差最小化

## 2. 系列データの分類(11章)

- ロジスティックモデル:
  - 一般化線形モデルの一種

$$q(y|\mathbf{x}; \boldsymbol{\theta}) = \frac{\exp \left( \sum_{j=1}^b \theta_j^{(y)} \phi_j(\mathbf{x}) \right)}{\sum_{y'=1}^c \exp \left( \sum_{j=1}^b \theta_j^{(y')} \phi_j(\mathbf{x}) \right)}$$

$$\boldsymbol{\theta} = \underbrace{(\theta_1^{(1)}, \dots, \theta_b^{(1)})}_{\text{class 1}}, \dots, \underbrace{(\theta_1^{(c)}, \dots, \theta_b^{(c)})}_{\text{class } c}^\top$$

- $(\boldsymbol{\theta}^{(y)})^\top \boldsymbol{\phi}(\mathbf{x})$  が大きい  $y$  ほど現れやすい

# 講義の流れ



## 1. 確率的分類(10章)

- A) ロジスティック回帰
- B) 確率的勾配法
- C) ロジスティック損失最小化
- D) 二乗誤差最小化

## 2. 系列データの分類(11章)

## ■ ロジスティックモデルに対する対数尤度

$$J_i(\boldsymbol{\theta}) = \log q(y_i | \mathbf{x}_i; \boldsymbol{\theta})$$

$$q(y | \mathbf{x}; \boldsymbol{\theta}) = \frac{\exp \left( \sum_{j=1}^b \theta_j^{(y)} \phi_j(\mathbf{x}) \right)}{\sum_{y'=1}^c \exp \left( \sum_{j=1}^b \theta_j^{(y')} \phi_j(\mathbf{x}) \right)}$$

の  $(\theta_1^{(y)}, \dots, \theta_b^{(y)})^\top$  に関する偏微分は次式で与えられることを示せ

$$\nabla_y J_i(\boldsymbol{\theta}) = - \frac{\exp \left( \sum_{j=1}^b \theta_j^{(y)} \phi_j(\mathbf{x}_i) \right) \phi(\mathbf{x}_i)}{\sum_{y'=1}^c \exp \left( \sum_{j=1}^b \theta_j^{(y')} \phi_j(\mathbf{x}_i) \right)} + \begin{cases} \phi(\mathbf{x}_i) & (y = y_i) \\ \mathbf{0} & (y \neq y_i) \end{cases}$$

# 確率的勾配法

1. パラメータ  $\theta$  を適当に初期化
2. 標本  $(x_i, y_i)$  をランダムに選び, 勾配を少し上昇


$$\theta^{(y)} \leftarrow \theta^{(y)} + \varepsilon \nabla_y J_i(\theta) \quad \text{for } y = 1, \dots, c$$

学習係数

$$\varepsilon > 0$$

$$\nabla_y J_i(\theta) = - \frac{\exp\left(\theta^{(y)\top} \phi(x_i)\right) \phi(x_i)}{\sum_{y'=1}^c \exp\left(\theta^{(y')\top} \phi(x_i)\right)} + \begin{cases} \phi(x_i) & (y = y_i) \\ 0 & (y \neq y_i) \end{cases}$$

3. 収束するまで 2. を繰り返す




# 実行例

## ■ 対数ガウスカーネルモデル

$$q(y|\mathbf{x}; \boldsymbol{\theta}) \propto \exp \left( \sum_{j=1}^n \theta_j K(\mathbf{x}, \mathbf{x}_j) \right)$$

$$K(\mathbf{x}, \mathbf{c}) = \exp \left( -\frac{\|\mathbf{x} - \mathbf{c}\|^2}{2h^2} \right)$$

に対するロジスティック回帰の実行例



# 実行例(続き)

17

```
clear all; rand('state',3); randn('state',3);

n=90; c=3; y=ones(n/c,1)*[1:c]; y=y(:);
x=randn(n/c,c)+repmat(linspace(-3,3,c),n/c,1);
x=x(:);

hh=2*1^2; t0=randn(n,c); e=0.1;
for o=1:n*1000
    i=ceil(rand*n); yi=y(i);
    ki=exp(-(x-x(i)).^2/hh);
    ci=exp(ki'*t0); t=t0-e*(ki*ci)/sum(ci);
    t(:,yi)=t(:,yi)+e*ki;
    if norm(t-t0)<0.000001, break, end
    t0=t;
end
```

次のページに続く



# 実行例(続き)

18

```
N=100; X=linspace(-5,5,N)';  
K=exp(-( repmat(X.^2,1,n)+repmat(x.^2',N,1)-  
2*X*x')/hh);  
  
figure(1); clf; hold on; axis([-5 5 -0.3 1.8]);  
C=exp(K*t); C=C./repmat(sum(C,2),1,c);  
plot(X,C(:,1),'b-'); plot(X,C(:,2),'r--');  
plot(X,C(:,3),'g:');  
plot(x(y==1),-0.1*ones(n/c,1),'bo');  
plot(x(y==2),-0.2*ones(n/c,1),'rx');  
plot(x(y==3),-0.1*ones(n/c,1),'gv');  
legend('q(y=1|x)', 'q(y=2|x)', 'q(y=3|x)')
```

# 講義の流れ



## 1. 確率的分類(10章)

- A) ロジスティック回帰
- B) 確率的勾配法
- C) ロジスティック損失最小化
- D) 二乗誤差最小化

## 2. 系列データの分類(11章)

- 2クラス問題  $y \in \{+1, -1\}$  に対して,  
ロジスティックモデル

$$q(y|\mathbf{x}; \boldsymbol{\alpha}) = \frac{\exp \left( \sum_{j=1}^b \alpha_j^{(y)} \phi_j(\mathbf{x}) \right)}{\sum_{y'=\pm 1} \exp \left( \sum_{j=1}^b \alpha_j^{(y')} \phi_j(\mathbf{x}) \right)}$$

は以下と等価であることを示せ

$$q(y|\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{1 + \exp(-y f_{\boldsymbol{\theta}}(\mathbf{x}))}$$

$$f_{\boldsymbol{\theta}}(\mathbf{x}) = \sum_{j=1}^b \theta_j \phi_j(\mathbf{x})$$

# ロジスティック損失最小化学習 22

$$q(y|\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{1 + \exp(-y f_{\boldsymbol{\theta}}(\mathbf{x}))}$$

$$f_{\boldsymbol{\theta}}(\mathbf{x}) = \sum_{j=1}^b \theta_j \phi_j(\mathbf{x})$$


■ このロジスティック回帰に対する最尤推定

$$\max_{\boldsymbol{\theta}} \sum_{i=1}^n \log q(y_i | \mathbf{x}_i; \boldsymbol{\theta})$$

はロジスティック損失  
最小化学習と等価

$$\min_{\boldsymbol{\theta}} \sum_{i=1}^n \log \left( 1 + \exp(-m_i) \right)$$

$$m_i = f_{\boldsymbol{\theta}}(\mathbf{x}_i) y_i$$



# 講義の流れ



## 1. 確率的分類(10章)

- A) ロジスティック回帰
- B) 確率的勾配法
- C) ロジスティック損失最小化
- D) 二乗誤差最小化

## 2. 系列データの分類(11章)

# 最小二乗確率的分類

- クラス  $y$  の事後確率に対する線形モデル:

$$q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) = \sum_{j=1}^b \theta_j^{(y)} \phi_j(\mathbf{x}) = \boldsymbol{\theta}^{(y)\top} \boldsymbol{\phi}(\mathbf{x})$$

- 必ずしも確率にはならない

- 二乗誤差最小化:

$$J_y(\boldsymbol{\theta}^{(y)}) = \frac{1}{2} \int \left( q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) - p(y|\mathbf{x}) \right)^2 p(\mathbf{x}) d\mathbf{x}$$

- 尤度最大化の場合は, モデルの正規化が必要
- 二乗誤差最小化の場合は, 正規化しなくてもよい!

# 二乗誤差の分解


25

$$J_y(\boldsymbol{\theta}^{(y)}) = \frac{1}{2} \int \left( q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) - p(y|\mathbf{x}) \right)^2 p(\mathbf{x}) d\mathbf{x}$$

$$= \frac{1}{2} \int q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)})^2 p(\mathbf{x}) d\mathbf{x}$$

$$- \int q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) p(y|\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

$$+ \frac{1}{2} \int p(y|\mathbf{x})^2 p(\mathbf{x}) d\mathbf{x}$$



定数なので  
無視できる

# 二乗誤差の標本近似

## ■ 二乗誤差の標本近似:

- $$\int q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)})^2 p(\mathbf{x}) d\mathbf{x} \quad \Rightarrow \quad \frac{1}{n} \sum_{i=1}^n q(y|\mathbf{x}_i; \boldsymbol{\theta}^{(y)})^2$$

- $$\int q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) p(y|\mathbf{x}) p(\mathbf{x}) d\mathbf{x}$$

$$= \int q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) p(y) p(\mathbf{x}|y) d\mathbf{x}$$

$$\Rightarrow \frac{1}{n_y} \sum_{i: y_i = y} q(y|\mathbf{x}_i; \boldsymbol{\theta}^{(y)}) \frac{n_y}{n}$$



## ■ 2次正則化項を加えた学習規準:

$$\hat{J}_y(\boldsymbol{\theta}^{(y)}) = \frac{1}{2n} \sum_{i=1}^n q(y|\mathbf{x}_i; \boldsymbol{\theta}^{(y)})^2$$

$$- \frac{1}{n} \sum_{i:y_i=y} q(y|\mathbf{x}_i; \boldsymbol{\theta}^{(y)}) + \frac{\lambda}{2n} \|\boldsymbol{\theta}^{(y)}\|^2$$

$$= \frac{1}{2n} \boldsymbol{\theta}^{(y)\top} \boldsymbol{\Phi}^\top \boldsymbol{\Phi} \boldsymbol{\theta}^{(y)} - \frac{1}{n} \boldsymbol{\theta}^{(y)\top} \boldsymbol{\Phi}^\top \boldsymbol{\pi}^{(y)} + \frac{\lambda}{2n} \|\boldsymbol{\theta}^{(y)}\|^2$$

## ■ 最小解は解析的に求まる:

$$\hat{\boldsymbol{\theta}}^{(y)} = \left( \boldsymbol{\Phi}^\top \boldsymbol{\Phi} + \lambda \mathbf{I} \right)^{-1} \boldsymbol{\Phi}^\top \boldsymbol{\pi}^{(y)}$$

$$\Phi_{i,j} = \phi_j(\mathbf{x}_i)$$

$$\pi_i^{(y)} = \begin{cases} 1 & (y_i = y) \\ 0 & (y_i \neq y) \end{cases}$$

$$\hat{\boldsymbol{\theta}}^{(y)} = \left( \boldsymbol{\Phi}^\top \boldsymbol{\Phi} + \lambda \boldsymbol{I} \right)^{-1} \boldsymbol{\Phi}^\top \boldsymbol{\pi}^{(y)}$$

- 確率は非負で和が1 → 解を事後補正する


$$\hat{p}(y|x) = \frac{\max(0, \hat{\boldsymbol{\theta}}^{(y)\top} \boldsymbol{\phi}(x))}{\sum_{y'=1}^c \max(0, \hat{\boldsymbol{\theta}}^{(y')\top} \boldsymbol{\phi}(x))}$$

# 実行例

## ■ ガウスカーネルモデル

$$q(y|x; \theta^{(y)}) = \sum_{j: y_j = y} \theta_j^{(y)} \exp \left( -\frac{\|x - x_j\|^2}{2h^2} \right)$$

に対する実行例



## ■ クラス事後確率 $p(y = \hat{y} | \mathbf{x})$ の学習に基づく分類:

$$\hat{y} = \operatorname{argmax}_{y=1,\dots,c} p(y | \mathbf{x})$$

- クラス予測に対する**信頼度**が得られる  
(信頼度が低い場合は自動分類をあきらめる等)
- **多クラス分類**が自然に行える

## ■ ロジスティック回帰:

- 名前は回帰だが, 分類学習法

## ■ 最小二乗確率的分類:

- 計算が簡単

# 講義の流れ



1. 確率的分類(10章)
2. 系列データの分類(11章)
  - A) 条件付き確率場モデル
  - B) 条件付き確率場モデルの学習
  - C) 条件付き確率場モデルによるラベル予測

# 系列データの認識

32

$$\overline{x} = (x^{(1)}, \dots, x^{(m)})$$

$$\overline{y} = (y^{(1)}, \dots, y^{(m)})$$

■ 例：手書き数字列の認識

1	4	7	4	6
---	---	---	---	---

■ 例：品詞の分解

こうぎ	が	ねむい
-----	---	-----

# 講義の流れ



1. 確率的分類(10章)
2. 系列データの分類(11章)
  - A) 条件付き確率場モデル
  - B) 条件付き確率場モデルの学習
  - C) 条件付き確率場モデルによるラベル予測

$\bar{x}$	$x^{(1)}$	$\dots$	$x^{(k-1)}$	$x^{(k)}$	$\dots$	$x^{(m)}$
$\bar{y}$	$y^{(1)}$	$\dots$	$y^{(k-1)}$	$y^{(k)}$	$\dots$	$y^{(m)}$

- 各データを1つずつ独立に学習・認識：
  - ロジスティック回帰をそのまま使えば良い

$$q(y|x; \theta) = \frac{\exp \left( \theta_y^\top \phi(x) \right)}{\sum_{y'=1}^c \exp \left( \theta_{y'}^\top \phi(x) \right)}$$

$$\theta = (\theta_1^\top, \dots, \theta_c^\top)^\top \in \mathbb{R}^{bc} : \text{パラメータ}$$

- しかし、系列データの特徴を生かせない



$\bar{x}$	$x^{(1)}$	$\dots$	$x^{(k-1)}$	$x^{(k)}$	$\dots$	$x^{(m)}$
$\bar{y}$	$y^{(1)}$	$\dots$	$y^{(k-1)}$	$y^{(k)}$	$\dots$	$y^{(m)}$


## ■ 全系列データを同時に認識:

- 系列データの特徴を完全に生かせる
- 学習が困難 (クラス数が  $c^m$ )

$$q(\bar{y}|\bar{x}; \bar{\theta}) = \frac{\exp\left(\bar{\theta}_{\bar{y}}^\top \bar{\phi}(\bar{x})\right)}{\sum_{\bar{y}'=1}^{c^m} \exp\left(\bar{\theta}_{\bar{y}'}^\top \bar{\phi}(\bar{x})\right)}$$

$\bar{\phi}(\bar{x}) = (\phi(x^{(1)})^\top, \dots, \phi(x^{(m)})^\top)^\top \in \mathbb{R}^{bm}$  : 基底ベクトル

$\bar{\theta}_{\bar{y}} = (\theta_{\bar{y}}^{(1)\top}, \dots, \theta_{\bar{y}}^{(m)\top})^\top \in \mathbb{R}^{bm}$  : パラメータ



- 系列データの特性を生かしつつ, モデルを適度に簡略化する
- 例: 隣り合ったデータのみの関連を考慮
  - 連続する2パターンに対応する $c^2$ クラスの認識問題を単に続けて解くのではなく, あくまでもパターン系列全体の認識を同時に行う.


$$q(\bar{y}|\bar{x}; \zeta) = \frac{\exp\left(\zeta^\top \varphi(\bar{x}, \bar{y})\right)}{\sum_{\bar{y}'=1}^{\bar{c}} \exp\left(\zeta^\top \varphi(\bar{x}, \bar{y}')\right)}$$

- 特徴ベクトルに  $\bar{y}$  を含める
- $\zeta = \bar{\theta}$  ,  $\varphi(\bar{x}, \bar{y}) = e_{\bar{y}}^{(\bar{c})} \otimes \bar{\phi}(\bar{x})$  とおけば, 系列全体に対するロジスティックモデルと等価

$$e_{\bar{y}}^{(\bar{c})} = (\underbrace{0, \dots, 0}_{\bar{y}-1}, 1, \underbrace{0, \dots, 0}_{\bar{c}-\bar{y}})^\top \in \mathbb{R}^{\bar{c}} \quad \bar{c} = c^m$$

$$(f_1, \dots, f_u)^\top \otimes \mathbf{g} = (f_1 \mathbf{g}^\top, \dots, f_u \mathbf{g}^\top)^\top$$

- パラメータ数が増え過ぎないように特徴ベクトルを定める




- 各時刻のラベルの分布がその時刻のパターンとその一つ前のラベルによって定まるモデル:

$$q(\bar{y}|\bar{x}; \zeta) = \prod_{k=1}^m q(y^{(k)} | x^{(k)}, y^{(k-1)}; \zeta) \quad y^{(0)} = y^{(1)}$$

$$\propto \prod_{k=1}^m \exp(\zeta^\top \varphi(x^{(k)}, y^{(k)}, y^{(k-1)}))$$

$$= \exp \left( \zeta^\top \sum_{k=1}^m \varphi(x^{(k)}, y^{(k)}, y^{(k-1)}) \right)$$



- 各時刻ごとの特徴を足し合わせるモデルに対応：

$$\varphi(\bar{x}, \bar{y}) = \sum_{k=1}^m \varphi(x^{(k)}, y^{(k)}, y^{(k-1)})$$

- **例**：  $(\phi(x^{(k)}), e_{y^{(k-1)}}^{(c)}) \in \mathbb{R}^{b+c}$  を改めて特徴とした  
ロジスティックモデル

$$\varphi(x^{(k)}, y^{(k)}, y^{(k-1)}) = e_{y^{(k)}}^{(c)} \otimes (\phi(x^{(k)}), e_{y^{(k-1)}}^{(c)}) \in \mathbb{R}^{c(b+c)}$$

$$e_y^{(c)} = (\underbrace{0, \dots, 0}_{y-1}, \underbrace{1, 0, \dots, 0}_{c-y})^\top \in \mathbb{R}^c$$

# 講義の流れ



1. 確率的分類(10章)
2. 系列データの分類(11章)
  - A) 条件付き確率場モデル
  - B) 条件付き確率場モデルの学習
  - C) 条件付き確率場モデルによるラベル予測

## ■ 系列データ

$$\left\{ (\bar{\mathbf{x}}_i, \bar{y}_i) \mid \bar{\mathbf{x}}_i = (\mathbf{x}_i^{(1)}, \dots, \mathbf{x}_i^{(m_i)}), \bar{y}_i = \sum_{k=1}^{m_i} c^{k-1} (y_i^{(k)} - 1) + 1 \right\}_{i=1}^n$$

からパラメータを最尤推定により学習:

$$\max_{\zeta} \sum_{i=1}^n \log \frac{\exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}_i) \right)}{\sum_{\bar{y}'=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}') \right)}$$

## ■ 確率的勾配法でパラメータを最適化:

$$\zeta \longleftarrow \zeta + \varepsilon \left( \varphi(\bar{\mathbf{x}}_i, \bar{y}_i) - \frac{\sum_{\bar{y}=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}) \right) \varphi(\bar{\mathbf{x}}_i, \bar{y})}{\sum_{\bar{y}'=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}') \right)} \right)$$

$$\zeta \leftarrow \zeta + \varepsilon \left( \varphi(\bar{\mathbf{x}}_i, \bar{y}_i) - \frac{\sum_{\bar{y}=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}) \right) \varphi(\bar{\mathbf{x}}_i, \bar{y})}{\sum_{\bar{y}'=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}') \right)} \right)$$

- $\sum_{\bar{y}=1}^{\bar{c}_i}$  の計算に  $\mathcal{O}(c^{m_i})$  時間かかる  
→ 分母と分子をそれぞれ動的計画法で計算

- 分母:  $\sum_{\bar{y}'=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}') \right)$

- 分子:  $\sum_{\bar{y}=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{\mathbf{x}}_i, \bar{y}) \right) \varphi(\bar{\mathbf{x}}_i, \bar{y})$



# 動的計画法による分母の計算 43

$$\sum_{\bar{y}'=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{x}_i, \bar{y}') \right)$$

■  $y^{(1)}, \dots, y^{(m_i-1)}$  と  $y^{(m_i)}$  に分解:

$$\sum_{y^{(1)}, \dots, y^{(m_i)}=1}^c \exp \left( \sum_{k=1}^{m_i} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) \right) = \sum_{y^{(m_i)}=1}^c A_{m_i}(y^{(m_i)})$$

$$A_\tau(y) = \sum_{y^{(1)}, \dots, y^{(\tau-1)}=1}^c \exp \left( \sum_{k=1}^{\tau-1} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) + \zeta^\top \varphi(x_i^{(\tau)}, y, y^{(\tau-1)}) \right)$$

$$A_\tau(y) = \sum_{y^{(1)}, \dots, y^{(\tau-1)}=1}^c \exp \left( \sum_{k=1}^{\tau-1} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) + \zeta^\top \varphi(x_i^{(\tau)}, y, y^{(\tau-1)}) \right)$$

■ 以下の再帰表現を求めよ

$$A_\tau(y^{(\tau)}) = \sum_{y^{(\tau-1)}=1}^c A_{\tau-1}(y^{(\tau-1)}) \exp \left( \zeta^\top \varphi(x_i^{(\tau)}, y^{(\tau)}, y^{(\tau-1)}) \right)$$



$A_\tau(y)$	$\tau = 1$	$\tau = 2$	$\dots$	$\tau = m$
$y = 1$				
$\vdots$				
$y = c$				

# 動的計画法による分子の計算 46

$$\sum_{\bar{y}=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{x}_i, \bar{y}) \right) \varphi(\bar{x}_i, \bar{y})$$

■  $y^{(1)}, \dots, y^{(k'-2)}$  と  $y^{(k'-1)}, y^{(k')}$  と  $y^{(k'+1)}, \dots, y^{(m_i)}$  に分解:

$$\begin{aligned} & \sum_{y^{(1)}, \dots, y^{(m_i)}=1}^c \exp \left( \sum_{k=1}^{m_i} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) \right) \left( \sum_{k'=1}^{m_i} \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)}) \right) \\ &= \sum_{k'=1}^{m_i} \sum_{y^{(1)}, \dots, y^{(k'-2)}=1}^c \sum_{y^{(k'-1)}, y^{(k')}=1}^c \sum_{y^{(k'+1)}, \dots, y^{(m_i)}=1}^c \\ & \quad \exp \left( \sum_{k=1}^{m_i} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) \right) \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)}) \end{aligned}$$

- $k < k' - 1$  に関する項と  $k > k'$  に関する項はexpの中でのみ現れるのでそれらを  $A_{k'-1}$  と  $B_{k'}$  で表現

# 動的計画法による分子の計算 47

$$\sum_{\bar{y}=1}^{\bar{c}_i} \exp \left( \zeta^\top \varphi(\bar{x}_i, \bar{y}) \right) \varphi(\bar{x}_i, \bar{y})$$

■  $y^{(1)}, \dots, y^{(k'-2)}$  と  $y^{(k'-1)}, y^{(k')}$  と  $y^{(k'+1)}, \dots, y^{(m_i)}$  に分解:

$$\sum_{y^{(1)}, \dots, y^{(m_i)}=1}^c \exp \left( \sum_{k=1}^{m_i} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) \right) \left( \sum_{k'=1}^{m_i} \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)}) \right)$$

$$= \sum_{k'=1}^{m_i} \sum_{y^{(1)}, \dots, y^{(k'-2)}=1}^c \sum_{y^{(k'-1)}, y^{(k')}=1}^c \sum_{y^{(k'+1)}, \dots, y^{(m_i)}=1}^c$$

$$\exp \left( \sum_{k=1}^{m_i} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) \right) \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)})$$

$$= \sum_{k'=1}^{m_i} \sum_{y^{(k'-1)}, y^{(k')}=1}^c \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)})$$

$$\times \exp \left( \zeta^\top \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)}) \right) A_{k'-1}(y^{(k'-1)}) B_{k'}(y^{(k')})$$

# 動的計画法による分子の計算 48

## (続き)

$$B_\tau(y) = \sum_{y^{(\tau+1)}, \dots, y^{(m_i)}=1}^c \exp \left( \sum_{k=\tau+2}^{m_i} \zeta^\top \varphi(x_i^{(k)}, y^{(k)}, y^{(k-1)}) + \zeta^\top \varphi(x_i^{(\tau+1)}, y^{(\tau+1)}, y) \right)$$

■  $B_\tau(y)$  は以下のように再帰表現できる 証明は宿題

$$B_\tau(y^{(\tau)}) = \sum_{y^{(\tau+1)}=1}^c B_{\tau+1}(y^{(\tau+1)}) \exp \left( \zeta^\top \varphi(x_i^{(\tau+1)}, y^{(\tau+1)}, y^{(\tau)}) \right)$$



$B_\tau(y)$	$\tau = 1$	$\tau = 2$	$\dots$	$\tau = m$
$y = 1$				
$\vdots$				
$y = c$				

# 動的計画法による勾配の計算 49

- $A_1(y^{(1)}), \dots, A_{m_i}(y^{(m_i)})$  の順に計算
- $B_{m_i}(y^{(m_i)}), \dots, B_1(y^{(1)})$  の順に計算
- これらを用いて勾配を効率良く計算:

● 分母: 
$$\sum_{y^{(m_i)}=1}^c A_{m_i}(y^{(m_i)})$$

$$\mathcal{O}(c^{m_i}) \longrightarrow \mathcal{O}(c^2 m_i)$$

“前向き後向きアルゴリズム”

● 分子: 
$$\sum_{k'=1}^{m_i} \sum_{y^{(k'-1)}, y^{(k')}=1}^c \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)})$$

$$\times \exp \left( \zeta^\top \varphi(x_i^{(k')}, y^{(k')}, y^{(k'-1)}) \right) A_{k'-1}(y^{(k'-1)}) B_{k'}(y^{(k')})$$

# 講義の流れ



1. 確率的分類(10章)
2. 系列データの分類(11章)
  - A) 条件付き確率場モデル
  - B) 条件付き確率場モデルの学習
  - C) 条件付き確率場モデルによるラベル予測

- 事後確率が最大のラベル系列を求める

$$\operatorname{argmax}_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}} q(\bar{y} | \bar{x}; \hat{\zeta})$$

$$q(\bar{y} | \bar{x}; \zeta) = \frac{\exp \left( \zeta^\top \varphi(\bar{x}, \bar{y}) \right)}{\sum_{\bar{y}'=1}^{\bar{c}} \exp \left( \zeta^\top \varphi(\bar{x}, \bar{y}') \right)}$$

- 式の簡略化

$$\operatorname{argmax}_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}} \frac{\exp \left( \hat{\zeta}^\top \varphi(\bar{x}, \bar{y}) \right)}{\sum_{\bar{y}'=1}^{\bar{c}} \exp \left( \hat{\zeta}^\top \varphi(\bar{x}, \bar{y}') \right)}$$

$$= \operatorname{argmax}_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}} \hat{\zeta}^\top \varphi(\bar{x}, \bar{y})$$

- $\operatorname{argmax}_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}}$  の計算に  $\mathcal{O}(c^m)$  時間かかる  
→ 動的計画法で計算



# 動的計画法による最大化の計算<sup>52</sup>

$$\operatorname{argmax}_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}} \hat{\zeta}^\top \varphi(\bar{x}, \bar{y})$$

■  $y^{(1)}, \dots, y^{(m-1)}$  と  $y^{(m)}$  に分解:

$$\max_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}} \hat{\zeta}^\top \varphi(\bar{x}, \bar{y}) = \max_{y^{(m)} \in \{1, \dots, c\}} P_m(y^{(m)})$$

$$P_\tau(y) = \max_{y^{(1)}, \dots, y^{(\tau-1)} \in \{1, \dots, c\}} \left[ \sum_{k=1}^{\tau-1} \hat{\zeta}^\top \varphi(x^{(k)}, y^{(k)}, y^{(k-1)}) + \hat{\zeta}^\top \varphi(x^{(\tau)}, y, y^{(\tau-1)}) \right]$$

■ 再帰表現:

証明は宿題

$$P_\tau(y^{(\tau)}) = \max_{y^{(\tau-1)} \in \{1, \dots, c\}} \left[ P_{\tau-1}(y^{(\tau-1)}) + \hat{\zeta}^\top \varphi(x^{(\tau)}, y^{(\tau)}, y^{(\tau-1)}) \right]$$

# 動的計画法による最大化の計算<sup>53</sup>

## (続き)

$$\operatorname{argmax}_{y^{(1)}, \dots, y^{(m)} \in \{1, \dots, c\}} q(\bar{y} | \bar{x}; \hat{\zeta})$$

$$q(\bar{y} | \bar{x}; \zeta) = \frac{\exp \left( \zeta^\top \varphi(\bar{x}, \bar{y}) \right)}{\sum_{\bar{y}'=1}^{\bar{c}} \exp \left( \zeta^\top \varphi(\bar{x}, \bar{y}') \right)}$$

$$P_\tau(y^{(\tau)}) = \max_{y^{(\tau-1)} \in \{1, \dots, c\}} \left[ P_{\tau-1}(y^{(\tau-1)}) + \hat{\zeta}^\top \varphi(x^{(\tau)}, y^{(\tau)}, y^{(\tau-1)}) \right]$$

- $P_1(y^{(1)}), \dots, P_m(y^{(m)})$  の順に計算
- これらを用いて最大化を効率良く計算:

$$\max_{y^{(k)} \in \{1, \dots, c\}} P_k(y^{(k)}), \quad k = 1, \dots, m$$

$$\mathcal{O}(c^m) \longrightarrow \mathcal{O}(c^2 m)$$

“Viterbiアルゴリズム”

## ■ 系列データの分類:


- 個別に分類すると系列としての性質を生かせない
- ナイーブに計算すると系列の長さの指数時間かかる

## ■ 条件付き確率場:

- 隣り合ったデータのみに関連を考慮
- 動的計画法により効率良く計算できる
- 系列データ以外にも拡張できる



# 講義の流れ



1. 確率的分類(10章)
2. 系列データの分類(11章)

## ■ 確率的分類

- クラス事後確率  $p(y = \hat{y} | \mathbf{x})$  の学習に基づく分類

$$\hat{y} = \operatorname{argmax}_{y=1, \dots, c} p(y | \mathbf{x})$$

- クラス予測に対する信頼度が得られる

## ■ 系列データの分類

- 動的計画法を用いることにより, 学習・予測を高速化
- 一般のグラフ構造に拡張できる
- マージン最大化原理に基づいた構造サポートベクトルマシンも提案されている

# 次回の予告

57

■ オンライン学習(15章)


# 宿題1

## ■ ガウスカーネルモデル

$$q(y|\mathbf{x}; \boldsymbol{\theta}^{(y)}) = \sum_{j: y_j = y} \theta_j^{(y)} \exp \left( -\frac{\|\mathbf{x} - \mathbf{x}_j\|^2}{2h^2} \right)$$

に対して，最小二乗確率的分類を実装せよ

```
n=90; c=3; y=ones(n/c,1)*[1:c]; y=y(:);
x=randn(n/c,c)+repmat(linspace(-3,3,c),n/c,1); x=x(:);
```



$$B_\tau(y) = \sum_{y^{(\tau+1)}, \dots, y^{(m_i)}=1}^c \exp \left( \sum_{k=\tau+2}^{m_i} \zeta^\top \varphi(\mathbf{x}_i^{(k)}, y^{(k)}, y^{(k-1)}) + \zeta^\top \varphi(\mathbf{x}_i^{(\tau+1)}, y^{(\tau+1)}, y) \right)$$

■  $B_\tau(y)$  は以下のように再帰表現できることを示せ

$$B_\tau(y^{(\tau)}) = \sum_{y^{(\tau+1)}=1}^c B_{\tau+1}(y^{(\tau+1)}) \exp \left( \zeta^\top \varphi(\mathbf{x}_i^{(\tau+1)}, y^{(\tau+1)}, y^{(\tau)}) \right)$$



$B_\tau(y)$	$\tau = 1$	$\tau = 2$	$\dots$	$\tau = m$
$y = 1$				
$\vdots$				
$y = c$				



$$P_\tau(y) = \max_{y^{(1)}, \dots, y^{(\tau-1)} \in \{1, \dots, c\}} \left[ \sum_{k=1}^{\tau-1} \hat{\zeta}^\top \varphi(\mathbf{x}^{(k)}, y^{(k)}, y^{(k-1)}) + \hat{\zeta}^\top \varphi(\mathbf{x}^{(\tau)}, y, y^{(\tau-1)}) \right]$$

■ 以下の再帰表現を求めよ

$$P_\tau(y^{(\tau)}) = \max_{y^{(\tau-1)} \in \{1, \dots, c\}} \left[ P_{\tau-1}(y^{(\tau-1)}) + \hat{\zeta}^\top \varphi(\mathbf{x}^{(\tau)}, y^{(\tau)}, y^{(\tau-1)}) \right]$$



$P_\tau(y)$	$\tau = 1$	$\tau = 2$	$\dots$	$\tau = m$
$y = 1$				
$\vdots$				
$y = c$				