

教師付き線形次元削減 (17章)

杉山将・本多淳也

sugi@k.u-tokyo.ac.jp, jhonda@k.u-tokyo.ac.jp


<http://www.ms.k.u-tokyo.ac.jp>

次元の呪い

2

入力の次元 d が増えたと
学習問題は**指数的**に難しくなる

■ 本質的な情報を保持したまま次元を減らしたい！



線形次元削減

■ (高次元) 標本:


$$\{\mathbf{x}_i\}_{i=1}^n, \quad \mathbf{x}_i \in \mathbb{R}^d, \quad d \gg 1$$

■ 埋め込み行列:

$$\mathbf{T} \in \mathbb{R}^{m \times d}, \quad 1 \leq m \ll d$$

■ 埋め込まれた標本


$$\{\mathbf{z}_i\}_{i=1}^n, \quad \mathbf{z}_i = \mathbf{T}\mathbf{x}_i \in \mathbb{R}^m$$



標本の中心化

- 以後，簡便のため標本を中心化して
平均がゼロになるようにしておく

$$\mathbf{x}_i \longleftarrow \mathbf{x}_i - \frac{1}{n} \sum_{i'=1}^n \mathbf{x}_{i'}$$



$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = 0$$

講義の流れ



1. フィッシャー判別分析(19章)
2. 局所フィッシャー判別分析(19章)
3. 半教師付き局所フィッシャー判別分析(19章)
4. 十分次元削減(19章)


教師付き次元削減

■ クラスタベル付きの標本: $\{(\mathbf{x}_i, y_i)\}_{i=1}^n$

$$\mathbf{x}_i \in \mathbb{R}^d$$

$$y_i \in \{1, 2, \dots, c\}$$

■ 異なるクラスの標本を分けるように次元削減を行ないたい.



散布行列

■ クラス内 (within-class) 散布行列:

$$\mathcal{S}^{(w)} = \sum_{y=1}^c \sum_{i:y_i=y} (\mathbf{x}_i - \boldsymbol{\mu}_y)(\mathbf{x}_i - \boldsymbol{\mu}_y)^{\top}$$


■ クラス間 (between-class) 散布行列:

$$\mathcal{S}^{(b)} = \sum_{y=1}^c n_y \boldsymbol{\mu}_y \boldsymbol{\mu}_y^{\top}$$

n_y : クラス y の標本数

$$\boldsymbol{\mu}_y = \frac{1}{n_y} \sum_{i:y_i=y} \mathbf{x}_i$$

$$\frac{1}{n} \sum_{i=1}^n \mathbf{x}_i = \mathbf{0}$$



散布行列の関係

■ 散布行列:

$$C = \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top$$

■ クラス間散布行列:

$$S^{(b)} = \sum_{y=1}^c n_y \boldsymbol{\mu}_y \boldsymbol{\mu}_y^\top$$

■ クラス内散布行列:

$$S^{(w)} = \sum_{y=1}^c \sum_{i:y_i=y} (\mathbf{x}_i - \boldsymbol{\mu}_y)(\mathbf{x}_i - \boldsymbol{\mu}_y)^\top$$

■ 数学演習: 以下の関係を示せ

$$C = S^{(w)} + S^{(b)}$$

解答例

9

$$S^{(w)} = \sum_{y=1}^c \sum_{i:y_i=y} (x_i x_i^\top - 2x_i \mu_y^\top + \mu_y \mu_y^\top)$$

$$= \sum_{i=1}^n x_i x_i^\top - 2 \sum_{y=1}^c n_y \mu_y \mu_y^\top + \sum_{y=1}^c n_y \mu_y \mu_y^\top = C - S^{(b)}$$

フィッシャー判別分析 (FDA: Fisher Discriminant Analysis)

- 埋め込み後の標本 $z_i = T x_i$ のクラス内・クラス外散布行列はそれぞれ $T S^{(b)} T^\top$, $T S^{(w)} T^\top$
- クラス内散布を小さく, クラス間散布を大きくする:

$$\mathbf{T}_{\text{FDA}} = \operatorname{argmax}_{\mathbf{T} \in \mathbb{R}^{m \times d}} \operatorname{tr} \left((T S^{(w)} T^\top)^{-1} T S^{(b)} T^\top \right)$$

フィッシャー判別分析 (FDA: Fisher Discriminant Analysis)

- クラス内散布を小さく, クラス間散布を大きくする:

$$\mathbf{T}_{\text{FDA}} = \operatorname{argmax}_{\mathbf{T} \in \mathbb{R}^{m \times d}} \operatorname{tr} \left((\mathbf{T} \mathbf{S}^{(\text{w})} \mathbf{T}^\top)^{-1} \mathbf{T} \mathbf{S}^{(\text{b})} \mathbf{T}^\top \right)$$



- 解の求め方:

- 一般化固有値問題を解く: $\mathbf{S}^{(\text{b})} \boldsymbol{\xi} = \lambda \mathbf{S}^{(\text{w})} \boldsymbol{\xi}$

$$\lambda_1 \geq \cdots \geq \lambda_d \quad \boldsymbol{\xi}_j^\top \mathbf{S}^{(\text{w})} \boldsymbol{\xi}_j = 1$$

- 上位 m 個の固有ベクトルを並べる

$$\mathbf{T}_{\text{FDA}} = (\boldsymbol{\xi}_1, \dots, \boldsymbol{\xi}_m)^\top$$



- フィッシャー判別分析によって、異なるクラスのデータを分離する部分空間が得られている
- しかし、クラス内にクラスタ構造があるとうまくいかないことがある

実装は宿題

フィッシャー判別分析の解

13

■ $y_i = \pm 1$ の2クラス分類問題を考え, フィッシャー判別分析により $m = 1$ 次元の部分空間を見つける

$$t_{\text{FDA}} = \operatorname{argmax}_{t \in \mathbb{R}^d} \frac{t^\top S^{(b)} t}{t^\top S^{(w)} t}$$

■ 目的関数がスケール変換に対して不変なのでこの最適化問題は以下と等価:

$$t_{\text{FDA}} = \operatorname{argmax}_{t \in \mathbb{R}^d} t^\top S^{(b)} t \quad \text{subject to } t^\top S^{(w)} t = 1$$

■ ラグランジュの乗数法より

$$S^{(b)} t_{\text{FDA}} + \lambda S^{(w)} t_{\text{FDA}} = 0$$

$$\mathbf{S}^{(b)} t_{\text{FDA}} + \lambda \mathbf{S}^{(w)} t_{\text{FDA}} = 0$$

- フィッシャー判別分析の解が以下の形で表されることを示せ：

$$t_{\text{FDA}} \propto \mathbf{C}^{-1} \boldsymbol{\mu}_{+1}$$

- ヒント：

- $\mathbf{C} = \mathbf{S}^{(w)} + \mathbf{S}^{(b)}$
- $\mathbf{S}^{(b)} = n_{+1} \boldsymbol{\mu}_{+1} \boldsymbol{\mu}_{+1}^{\top} + n_{-1} \boldsymbol{\mu}_{-1} \boldsymbol{\mu}_{-1}^{\top}$
- 中心化の仮定より $n_{+1} \boldsymbol{\mu}_{+1} + n_{-1} \boldsymbol{\mu}_{-1} = \mathbf{0}$
- 任意の t に対し $(\boldsymbol{\mu}_{+1} \boldsymbol{\mu}_{+1}^{\top}) t = \boldsymbol{\mu}_{+1} (\boldsymbol{\mu}_{+1}^{\top} t) \propto \boldsymbol{\mu}_{+1}$

- $S^{(b)} t_{\text{FDA}} + \lambda S^{(w)} t_{\text{FDA}} = 0$ と $C = S^{(w)} + S^{(b)}$ より

$$S^{(b)} t_{\text{FDA}} + \lambda (C - S^{(b)}) t_{\text{FDA}} = 0$$

- C^{-1} を左からかけて整理すると

$$\lambda t_{\text{FDA}} = (\lambda - 1) C^{-1} S^{(b)} t_{\text{FDA}}$$

- 一方で

$$S^{(b)} = n_{+1} \mu_{+1} \mu_{+1}^{\top} + n_{-1} \mu_{-1} \mu_{-1}^{\top}$$

$$= n_{+1} \mu_{+1} \mu_{+1}^{\top} + \frac{n_{-1}^2}{n_{-1}} \mu_{-1} \mu_{-1}^{\top} \propto \mu_{+1} \mu_{+1}^{\top}$$

なので

$$t_{\text{FDA}} \propto C^{-1} (\mu_{+1} \mu_{+1}^{\top}) t_{\text{FDA}} \propto C^{-1} \mu_{+1}$$

フィッシャー判別分析の等価性 16

■ ガウス生成モデルの最尤推定での分離平面:

$$\mathbf{a}^\top \mathbf{x} + b = 0$$

$$\mathbf{a} = \mathbf{C}^{-1} \boldsymbol{\mu}_{+1}$$

■ 線形最小二乗分類:



$$y_i \in \left\{ \frac{n}{n_{+1}}, \frac{n}{n_{-1}} \right\}$$

$$\hat{\boldsymbol{\theta}} = \operatorname{argmin}_{\boldsymbol{\theta}} \sum_{i=1}^n \left(\boldsymbol{\theta}^\top \mathbf{x}_i - y_i \right)^2 \propto \mathbf{C}^{-1} \boldsymbol{\mu}_{+1}$$

■ 線形次元削減法:

$$t_{\text{FDA}} \propto \mathbf{C}^{-1} \boldsymbol{\mu}_{+1}$$

- 1次元部分空間に射影した後にしきい値処理



埋め込み次元数の上限

17

■ $\text{rank}(S^{(b)}) \leq c - 1$ が成り立つ c : クラス数

● 証明: $S^{(b)}$ のランク = 空間 $\{S^{(b)}t : t \in \mathbb{R}^d\}$ の次元

$$S^{(b)}t = \sum_{y=1}^c n_y \mu_y \mu_y^\top t = \sum_{y=1}^c n_y (\mu_y^\top t) \cdot \mu_y$$

● 中心化の仮定 $\sum_{y=1}^c n_y \mu_y = 0$ より $\{\mu_y\}$ は一時従属



■ 一般化固有値問題 $S^{(b)}\xi = \lambda S^{(w)}\xi$ の固有値ゼロに対応する解は無意味

■ 埋め込み空間の次元数 m は最大 $c - 1$

● $c = 2$ のときは高々 $m = 1$ となってしまう

フィッシャー判別分析:まとめ

18



- 一般化固有ベクトルから解析的に解が求まる
- 異なるクラスデータを分離できる
- クラス内クラスタ構造があるとうまくいかなことがある
- 埋め込み空間の次元に上限がある

講義の流れ



1. フィッシャー判別分析(19章)
2. 局所フィッシャー判別分析(19章)
3. 半教師付き局所フィッシャー判別分析(19章)
4. 十分次元削減(19章)

散布行列のペア表現

20

■ クラス内:
$$S^{(w)} = \frac{1}{2} \sum_{i,i'=1}^n Q_{i,i'}^{(w)} (\mathbf{x}_i - \mathbf{x}_{i'}) (\mathbf{x}_i - \mathbf{x}_{i'})^\top$$

$$Q_{i,i'}^{(w)} = \begin{cases} 1/n_y & (y_i = y_{i'} = y) \\ 0 & (y_i \neq y_{i'}) \end{cases}$$

■ クラス間:
$$S^{(b)} = \frac{1}{2} \sum_{i,i'=1}^n Q_{i,i'}^{(b)} (\mathbf{x}_i - \mathbf{x}_{i'}) (\mathbf{x}_i - \mathbf{x}_{i'})^\top$$

導出は宿題
$$Q_{i,i'}^{(b)} = \begin{cases} 1/n - 1/n_y \leq 0 & (y_i = y_{i'} = y) \\ 1/n & (y_i \neq y_{i'}) \end{cases}$$

n : 全標本数

n_y : クラス y の標本数

■ クラス内: $TS^{(w)}T^\top = \frac{1}{2} \sum_{i,i'=1}^n Q_{i,i'}^{(w)} (z_i - z_{i'})(z_i - z_{i'})^\top$

$$Q_{i,i'}^{(w)} = \begin{cases} 1/n_y & (y_i = y_{i'} = y) \\ 0 & (y_i \neq y_{i'}) \end{cases}$$

■ クラス間: $TS^{(b)}T^\top = \frac{1}{2} \sum_{i,i'=1}^n Q_{i,i'}^{(b)} (z_i - z_{i'})(z_i - z_{i'})^\top$

$$Q_{i,i'}^{(b)} = \begin{cases} 1/n - 1/n_y \leq 0 & (y_i = y_{i'} = y) \\ 1/n & (y_i \neq y_{i'}) \end{cases}$$


■ FDA: $TS^{(w)}T^\top$ は小さく, $TS^{(b)}T^\top$ は大きくする

- 同じクラスの標本は近づける
- 異なるクラスの標本は遠ざける

局所フィッシャー判別分析 (LFDA: Local FDA)

■ **考え方**: データの局所性も考慮に入れる

- A) 同じクラスの**近く**の標本は近づける
- B) 異なるクラスの標本は遠ざける
- C) 同じクラスの**遠く**の標本は近づける必要はない



局所フィッシャー判別分析
||
フィッシャー判別分析
+
局所性保存射影

局所フィッシャー判別分析の規準²³

■ 局所クラス内散布行列:

W : 類似度行列

$$S^{(lw)} = \frac{1}{2} \sum_{i,i'=1}^n Q_{i,i'}^{(lw)} (\mathbf{x}_i - \mathbf{x}_{i'}) (\mathbf{x}_i - \mathbf{x}_{i'})^\top$$

$$Q_{i,i'}^{(lw)} = \begin{cases} W_{i,i'} / n_y & (y_i = y_{i'} = y) \\ 0 & (y_i \neq y_{i'}) \end{cases}$$



■ 局所クラス間散布行列:

$$S^{(lb)} = \frac{1}{2} \sum_{i,i'=1}^n Q_{i,i'}^{(lb)} (\mathbf{x}_i - \mathbf{x}_{i'}) (\mathbf{x}_i - \mathbf{x}_{i'})^\top$$

$$Q_{i,i'}^{(lb)} = \begin{cases} W_{i,i'} (1/n - 1/n_y) & (y_i = y_{i'} = y) \\ 1/n & (y_i \neq y_{i'}) \end{cases}$$

■ 規準:

$$T_{\text{LFDA}} = \operatorname{argmax}_{T \in \mathbb{R}^{m \times d}} \operatorname{tr} \left((TS^{(lw)} T^\top)^{-1} TS^{(lb)} T^\top \right)$$





- クラス内にクラスタ構造があっても，異なるクラスのデータを分離する部分空間が得られている
- 任意の次元数に次元削減できる

- 甲状腺疾患データ(5次元の検査データ)
 - ラベル: 正常か異常
 - 甲状腺異常には
 - 機能亢進(こうしん): 機能が強すぎる
 - 機能低下: 機能が弱すぎる
- の2種類がある

可視化結果(一次元)

26


フィッシャー判別分析



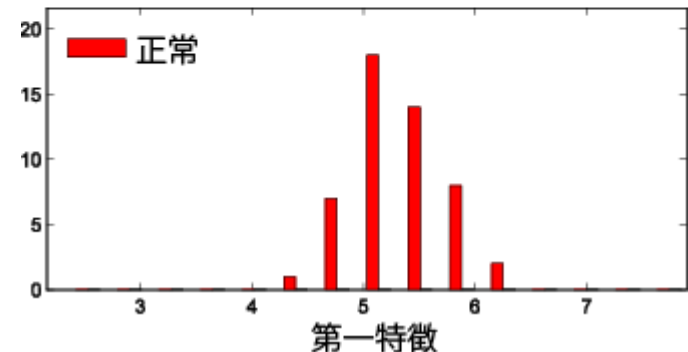
- 正常と異常はうまく分かれる
- 機能亢進と低下は混ざってしまう

局所フィッシャー判別分析

異常





正常




- 正常と異常はうまく分かれる
- 機能亢進と低下もうまく分かれる
- 見つかった特徴は甲状腺機能のレベルと強い負の相関

局所フィッシャー判別分析:まとめ²⁷



- 一般化固有ベクトルから解析的に解が求まる
- クラス内クラスタ構造に対応できる
- 埋め込み空間の次元に上限がない
- 結果が類似度行列の選び方に依存する(交差確認可)

講義の流れ




1. フィッシャー判別分析(19章)
2. 局所フィッシャー判別分析(19章)
3. 半教師付き局所フィッシャー判別分析(19章)
4. 十分次元削減(19章)

教師付き次元削減の問題点

29

- ラベルありデータが少ない場合，過適合しやすい



半教師付き次元削減

■ 半教師付き学習:

- 少数のラベルあり標本

$$\{(x_i, y_i)\}_{i=1}^n$$

- 多数のラベルなし標本


$$\{x_i\}_{i=n+1}^{n'}$$

■ 教師付き次元削減法は, 少数のラベルあり標本に過適合しやすい

■ 多数のラベルなし標本の情報も活用したい

- 主成分分析(PCA)は元々ラベルの情報を利用しない

半教師付き学習における LFDAとPCA



- LFDA: 過適合しやすい
- PCA: ラベルの情報を利用していない
- LFDAとPCAは相補的な傾向がある

半教師付き局所フィッシャー判別分析³² (SELF: Semi-Supervised LFDA)

- **基本アイデア**: LFDAとPCAのいいところを組み合わせる
- **着目点**: LFDAとPCAは同じ形式の固有値問題
 - PCA: $C\xi = \lambda\xi$
 - LFDA: $S^{(lb)}\xi = \lambda S^{(lw)}\xi$
- **方針**: 固有値問題を組み合わせる

■ SELFの固有値問題: LFDAとPCAの重みつき和

$$S^{(\text{rlb})} \xi = \lambda S^{(\text{rlw})} \xi$$

- 正則化局所クラス内散布行列

$$S^{(\text{rlw})} = (1 - \beta) S^{(\text{lw})} + \beta \mathbf{I}_d \quad 0 \leq \beta \leq 1$$

- 正則化局所クラス間散布行列

$$S^{(\text{rlb})} = (1 - \beta) S^{(\text{lb})} + \beta \mathbf{C}$$


■ 解: 上位の固有ベクトルを並べる

顔画像データの可視化


■ メガネ vs. メガネなし




SELF


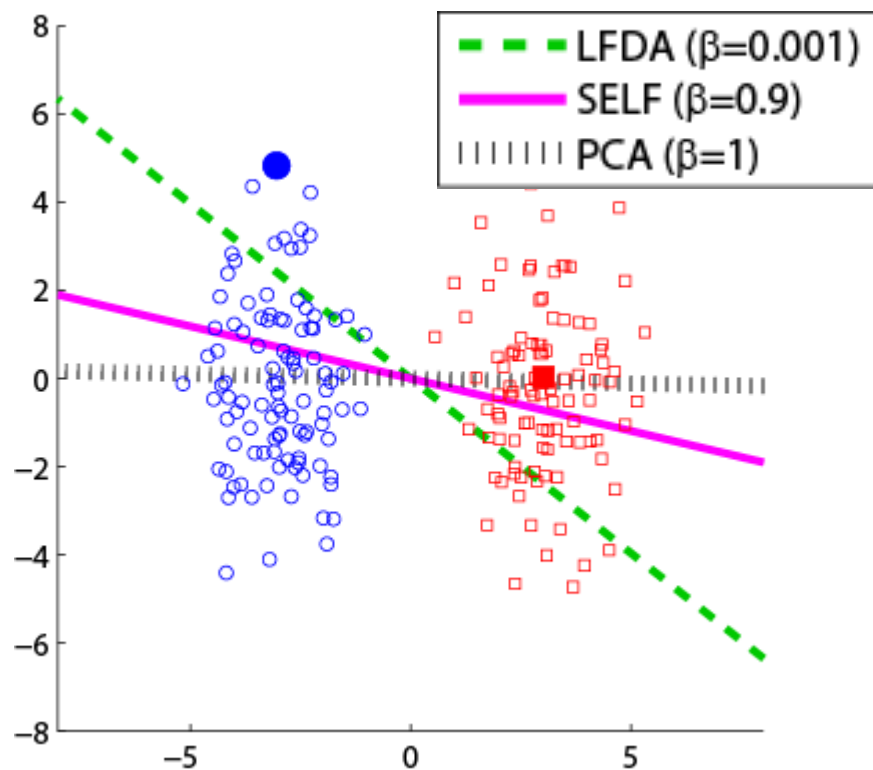


PCA:ラベルが混合



LFDA: 過適合





- 半教師付き局所フィッシャー判別分析によって、過適合が回避できている

半教師付き局所フィッシャー 判別分析:まとめ

- 教師なし主成分分析と教師付き局所フィッシャー判別分析との組み合わせ
- 一般化固有ベクトルから解析的に解が求まる
- 過適合を回避できる
- 混合比 β の決定は難しい


講義の流れ



1. フィッシャー判別分析(19章)
2. 局所フィッシャー判別分析(19章)
3. 半教師付き局所フィッシャー判別分析(19章)
4. 十分次元削減(19章)

十分次元削減

- 判別分析は y がカテゴリ値を取る**分類**専用
- y が実数値を取る**回帰**問題の次元削減は？
- y の**情報**を最大限含む z を求める
 - z を与えたとき, x, y が独立になるようにする



$$\{z_i\}_{i=1}^n, \quad z_i = \mathbf{T} \mathbf{x}_i \in \mathbb{R}^m$$

$$p(\mathbf{x}, y | \mathbf{z}) = p(\mathbf{x} | \mathbf{z}) p(y | \mathbf{z})$$

(z は y の分布の十分統計量)

相互情報量

$$\text{MI}(\mathbf{X}, Y) = \iint p(\mathbf{x}, y) \log \frac{p(\mathbf{x}, y)}{p(\mathbf{x})p(y)} d\mathbf{x}dy$$

- \mathbf{X} がわかったとき Y について得られる情報量

■ 相互情報量によって独立性を測れる:

- $\text{MI}(\mathbf{X}, Y) \geq 0$

- $\text{MI}(\mathbf{X}, Y) = 0$



\mathbf{X} と Y は独立

$$p(\mathbf{x}, y) = p(\mathbf{x})p(y)$$

$$\text{MI}(\mathbf{X}, Y) = \iint p(\mathbf{x}, y) \log \frac{p(\mathbf{x}, y)}{p(\mathbf{x})p(y)} d\mathbf{x} dy$$

$$\{\mathbf{z}_i\}_{i=1}^n, \quad \mathbf{z}_i = \mathbf{T}\mathbf{x}_i \in \mathbb{R}^m$$

■ 相互情報量によって条件付き独立性も測れる:

- $\text{MI}(\mathbf{X}, Y) \geq \text{MI}(\mathbf{Z}, Y)$:

\mathbf{Z} がもつ Y の情報は \mathbf{X} がもつ Y の情報より少ない

- $\text{MI}(\mathbf{X}, Y) = \text{MI}(\mathbf{Z}, Y)$



x と y は条件付き独立

$$p(\mathbf{x}, y | \mathbf{z}) = p(\mathbf{x} | \mathbf{z}) p(y | \mathbf{z})$$

相互情報量最大化による 十分次元削減

■ $\max_{\mathbf{T} \in \mathbb{R}^{m \times d}} \text{MI}(\mathbf{Z}, Y) \quad \text{subject to } \mathbf{T}\mathbf{T}^\top = \mathbf{I}_m$

$$\text{MI}(\mathbf{Z}, Y) = \iint p(\mathbf{z}, y) \log \frac{p(\mathbf{z}, y)}{p(\mathbf{z})p(y)} d\mathbf{z} dy$$

$$\{\mathbf{z}_i\}_{i=1}^n, \quad \mathbf{z}_i = \mathbf{T}\mathbf{x}_i \in \mathbb{R}^m$$

■ 勾配法により行列 \mathbf{T} を最適化する

- $\mathbf{T} \leftarrow \mathbf{T} + \varepsilon \nabla \widehat{\text{MI}}(\mathbf{T}\mathbf{X}, Y) \quad \varepsilon > 0 : \text{ステップ幅}$

- $\mathbf{T}\mathbf{T}^\top = \mathbf{I}_m$ を満たすように正規直交化

■ しかし、一般に局所解しか見つけられない

十分次元削減:まとめ

42

- 出力の情報を最大限含む部分空間を探索
- 回帰, 分類両方に適用可能
- 情報量の推定に工夫が必要
- 部分空間の探索にも工夫が必要
- 実装に比較的手間がかかる

講義の流れ



1. フィッシャー判別分析(19章)
2. 局所フィッシャー判別分析(19章)
3. 半教師付き局所フィッシャー判別分析(19章)
4. 十分次元削減(19章)

- **次元の呪い**: 高次元データは非常に扱いにくい
- **次元削減**: データの特徴を残しつつ次元を削減
- **教師なし次元削減**
 - **主成分分析(PCA)**: もとのデータを保存
 - **局所性保存射影(LPP)**: クラスタ構造を保存
- **教師付き次元削減**
 - **フィッシャー判別分析(FDA)**: クラス間の分離性を保存
 - **局所FDA(LFDA)**: FDAとLPPの組み合わせ
 - **半教師付きLFDA**: LFDAとPCAの組み合わせ
 - **十分次元削減**: 回帰にも適用可能



次回の予告



- カーネルを用いた非線形次元削減(13章)
- 来週は休講, 次回は7/4です

■ フィッシャー判別分析を実装せよ:

```
clear all; rand('state',0); randn('state',0);  
n=100; x=randn(n,2);  
x(1:n/2,1)=x(1:n/2,1)-4; x(n/2+1:end,1)=x(n/2+1:end,1)+4;  
%x(1:n/4,1)=x(1:n/4,1)-4; x(n/4+1:n/2,1)=x(n/4+1:n/2,1)+4;  
x=x-repmat(mean(x),[n,1]); y=[ones(n/2,1); 2*ones(n/2,1)];
```



宿題2

■ 以下の散布行列のペア表現を求めよ n : 全標本数

● クラス内:

n_y : クラス y の標本数

$$S^{(w)} = \frac{1}{2} \sum_{i, i'=1}^n Q_{i, i'}^{(w)} (\mathbf{x}_i - \mathbf{x}_{i'}) (\mathbf{x}_i - \mathbf{x}_{i'})^\top$$

$$Q_{i, i'}^{(w)} = \begin{cases} 1/n_y & (y_i = y_{i'} = y) \\ 0 & (y_i \neq y_{i'}) \end{cases}$$

● クラス間:

$$S^{(b)} = \frac{1}{2} \sum_{i, i'=1}^n Q_{i, i'}^{(b)} (\mathbf{x}_i - \mathbf{x}_{i'}) (\mathbf{x}_i - \mathbf{x}_{i'})^\top$$

$$Q_{i, i'}^{(b)} = \begin{cases} 1/n - 1/n_y & (y_i = y_{i'} = y) \\ 1/n & (y_i \neq y_{i'}) \end{cases}$$

$S^{(w)}$ の表現:

$$S^{(w)} = \sum_{y=1}^c \sum_{i:y_i=y} (x_i - \mu_y)(x_i - \mu_y)^\top$$

$$\mu_y = \frac{1}{n_y} \sum_{i':y_{i'}=y} x_{i'}$$

$S^{(b)}$ の表現:

■ C のペア表現を求め, $S^{(b)} = C - S^{(w)}$ を利用

■ 中心化の仮定 $\sum_i x_{i'} = 0$ より $\sum_{i=1}^n x_i \sum_{i'=1}^n x_{i'}^\top = 0$