

# カーネルを用いた 非線形次元削減(13章)

杉山将・本多淳也

[sugi@k.u-tokyo.ac.jp](mailto:sugi@k.u-tokyo.ac.jp), [jhonda@k.u-tokyo.ac.jp](mailto:jhonda@k.u-tokyo.ac.jp)


<http://www.ms.k.u-tokyo.ac.jp>

# 次元削減

- 本質的な情報を保持したまま次元を減らしたい！

もとの高次元データ

次元削減後のデータ(2d)



- 1～3次元に減らせば, データを可視化できる.
- 次元削減の基本的な仮定:
  - 手持ちの高次元データはある意味で冗長である

# 線形次元削減

■ (高次元) 標本:


$$\{\mathbf{x}_i\}_{i=1}^n, \quad \mathbf{x}_i \in \mathbb{R}^d, \quad d \gg 1$$

■ 埋め込み行列:

$$\mathbf{T} \in \mathbb{R}^{m \times d}, \quad 1 \leq m \ll d$$

■ 埋め込まれた標本

$$\{\mathbf{z}_i\}_{i=1}^n, \quad \mathbf{z}_i = \mathbf{T}\mathbf{x}_i \in \mathbb{R}^m$$



# 様々な線形次元削減法

4

## ■教師無し次元削減


- 主成分分析(PCA): もとのデータを保存
- 局所性保存射影(LPP): クラスタ構造を保存

## ■教師付き次元削減

- フィッシャー判別分析(FDA): クラス間の分離性を保存

# 線形次元削減の限界

- データの分布が曲がっているとき、  
原理的に線形次元削減法では  
うまく構造を抽出できない



# 講義の流れ



## 1. カーネル主成分分析(13章)

- A) 双対空間における直接的計算法
- B) カーネルを用いた間接的計算法
- C) カーネルについて

## 2. ラプラス固有写像(13章)


# 主成分分析

■ 射影誤差の和を最小にする:

$$\mathbf{T}_{\text{PCA}} = \underset{\mathbf{T} \in \mathbb{R}^{m \times d}}{\operatorname{argmin}} \left[ \sum_{i=1}^n \|\mathbf{T}^\top \mathbf{T} \mathbf{x}_i - \mathbf{x}_i\|^2 \right]$$

$$\text{subject to } \mathbf{T}\mathbf{T}^\top = \mathbf{I}_m$$

(正規直交性の拘束条件をつける)



# 主成分分析の解の求め方

8

## 1. 固有値問題を解く:

$$\mathbf{x}_i \longleftarrow \mathbf{x}_i - \frac{1}{n} \sum_{i'=1}^n \mathbf{x}_{i'} \quad \text{中心化}$$

$$C\xi = \lambda\xi$$

$$C = \sum_{i=1}^n \mathbf{x}_i \mathbf{x}_i^\top \quad \text{標本の散布行列}$$

- 固有値を降順にソート:  $\lambda_1 \geq \dots \geq \lambda_d$
- 固有ベクトルを正規化:  $\|\xi_j\| = 1$

## 2. 上位 $m$ 個の固有ベクトルを並べる:

$$\mathbf{T}_{\text{PCA}} = U(\xi_1, \dots, \xi_m)^\top$$

$U$  : 任意の直交行列





# 線形次元削減法の問題点

9

- データの分布が曲がっていると、うまくいかない

線形の主成分分析



# 講義の流れ



## 1. カーネル主成分分析(13章)

- A) 双対空間における直接的計算法
- B) カーネルを用いた間接的計算法
- C) カーネルについて


## 2. ラプラス固有写像(13章)

# 線形の手法を非線形にする方法<sup>11</sup>

1. もとのデータを特徴空間に**非線形変換**する.
2. 線形次元削減法を特徴空間で実行する.
3. 結果をもとの空間に戻す.

もとの空間  $\mathbb{R}^d$

$$\{x_i\}_{i=1}^n$$




$$f = \phi(x)$$

非線形変換

特徴空間  $\mathcal{F}$

$$\{f_i\}_{i=1}^n$$




# 非線形主成分分析の例


12

■ **特徴空間**で主成分分析を行なう.


もとの標本



特徴空間内での標本



特徴空間内での  
主成分分析




$$x = \begin{pmatrix} a \\ b \end{pmatrix} \longrightarrow f = \begin{pmatrix} r \\ \theta \end{pmatrix}$$

$$\begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} r \cos \theta \\ r \sin \theta \end{pmatrix}$$


# 非線形主成分分析の例(続き) 13

- 結果をもとの空間に戻す.

非線形  
主成分分析



線形  
主成分分析




# 固有値問題

- 固有値問題  $C\psi = \lambda\psi$  の解を用いて,  
固有値問題  $K\alpha = \lambda\alpha$  の解を求められる

$$C = FF^\top \quad K = F^\top F \quad F = (f_1, \dots, f_n)$$

- また, その逆も可能である



# 固有値問題

- 固有方程式  $FF^\top \psi = \lambda \psi$  の左から  $F^\top$  をかけると

$$F^\top FF^\top \psi = \lambda F^\top \psi$$

$$C = FF^\top$$

$$K = F^\top F$$

ここで  $\alpha = F^\top \psi$  とおけば  $K\alpha = \lambda\alpha$


- 固有方程式  $F^\top F\alpha = \lambda\alpha$  の左から  $F$  をかけると

$$FF^\top F\alpha = \lambda F\alpha$$

ここで  $\psi = F\alpha$  とおけば  $C\psi = \lambda\psi$

# 特徴空間の次元

- 高次元の特徴空間を用いれば,
  - アルゴリズムの能力は高まる.
  - しかし, 計算時間は増加してしまう.
- $n < \dim(\mathcal{F})$  のとき, 双対問題の方が速く解ける.





- 双対問題  $K\alpha = \lambda\alpha$  の正規化された固有ベクトル  $\|\alpha\| = 1$  を用いて、主問題  $C\psi = \lambda\psi$  の正規化された固有ベクトルが

$$\frac{\psi}{\|\psi\|} = \frac{1}{\sqrt{\lambda}} F\alpha$$

で与えられることを示せ

- ヒント:  $\psi = F\alpha$  と  $F^\top F\alpha = \lambda\alpha$  を使う

# 埋め込み行列の計算

19

■ 特徴空間上での埋め込み行列:

$$\mathbf{T}_{\text{PCA}} = (\boldsymbol{\xi}_1, \dots, \boldsymbol{\xi}_m)^\top$$

$$= \left( \frac{\boldsymbol{\psi}_m}{\|\boldsymbol{\psi}_m\|}, \dots, \frac{\boldsymbol{\psi}_m}{\|\boldsymbol{\psi}_m\|} \right)^\top$$

$$= \left( \frac{\boldsymbol{\alpha}_1}{\sqrt{\lambda_1}}, \dots, \frac{\boldsymbol{\alpha}_m}{\sqrt{\lambda_m}} \right)^\top \mathbf{F}^\top$$

$$= \boldsymbol{\Lambda}^{-1/2} (\boldsymbol{\alpha}_1, \dots, \boldsymbol{\alpha}_m)^\top \mathbf{F}^\top$$

$$= \boldsymbol{\Lambda}^{-1/2} \mathbf{A}^\top \mathbf{F}^\top$$

$$\boldsymbol{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_m)$$

$$\mathbf{A} = (\boldsymbol{\alpha}_1, \dots, \boldsymbol{\alpha}_m)^\top$$

## ■ 特徴の中心化:

$$f_i \longleftarrow f_i - \frac{1}{n} \sum_{i'=1}^n f_{i'}$$

$$C\psi = \lambda\psi \quad K\alpha = \lambda\alpha$$

$$\lambda_1 \geq \dots \geq \lambda_n \quad \|\alpha_j\| = 1$$

## ■ 特徴 $f$ の埋め込み結果:

$$\Lambda^{-\frac{1}{2}} A^\top F^\top f = \Lambda^{-\frac{1}{2}} A^\top k$$

$$k_i = f_i^\top f$$

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$$

$$A = (\alpha_1, \dots, \alpha_m)^\top$$

$I$ : 単位行列


$1$ : 全てが1のベクトル・行列

## ■ 元のデータ $\{x_i\}_{i=1}^n$ を埋め込むときは

$$\Lambda^{-\frac{1}{2}} A^\top K \quad K = F^\top F$$

- 手持ちの訓練標本を**非線形変換**し, 変換後の標本に対して主成分分析を適用する
  - これにより, もとの標本に対しては非線形な主成分分析を行なったことになる
- 非線形変換後の標本の次元が高い時は計算量が増加する
  - 訓練標本数が次元数より小さいときは, **双対問題**を解く方が効率が良い

# 講義の流れ



## 1. カーネル主成分分析(13章)

- A) 双対空間における直接的計算法
- B) カーネルを用いた間接的計算法
- C) カーネルについて


## 2. ラプラス固有写像(13章)

$$K_{i,i'} = f_i^\top f_{i'}$$

$$k_i = f^\top f_i$$

- $K$  と  $k$  が与えられれば, 双対問題を解くための計算量は  $\dim(\mathcal{F})$  によらない.
- しかし,  $K$  と  $k$  の計算は  $\dim(\mathcal{F})$  に依存する.

$$f^\top f' = \sum_{j=1}^{\dim(\mathcal{F})} f^{(j)} f'^{(j)}$$



# カーネル・トリック

$$f^\top f' = \sum_{j=1}^{\dim(\mathcal{F})} f^{(j)} f'^{(j)}$$

- もし上記の積和が閉じた形で書ければ、内積の値は一発で計算できる.
- 実用的には、逆に上記の積和が閉じた形で書けるような特徴ベクトル  $f$  を考えればよい！
- 任意の半正値カーネル  $K(x, x')$  に対して、

$$K(x, x') = f^\top f'$$

を満たす特徴ベクトル  $f, f'$  が常に存在する.

$$\forall x, x', \quad K(x, x') \geq 0$$

## ■ 多項式カーネル

$$K(x, x') = (x^\top x')^c \quad x \in \mathbb{R}^d \quad c \in \mathbb{N}$$

に対応する特徴ベクトル  $f$  を  $d = 2, c = 2$  に対して明示的に求めよ

■ ヒント:  $x = \begin{pmatrix} s \\ t \end{pmatrix}$  において  $(x^\top x')^2$  を明示的に計算



$$K(x, x') = \exp(-\|x - x'\|^2 / c^2) \quad c > 0$$

- 特徴ベクトル  $f$  の形は明示的には分らない.
- 気持ちは悪いが, 計算する上では何の支障もない.

$$f^\top f' = K(x, x')$$

- 暗に定義されている特徴空間は無限次元！

$$\dim(\mathcal{F}) = \infty$$

# 中心化

## ■ 中心化した特徴ベクトル

$$\bar{f}_i = f_i - \frac{1}{n} \sum_{i'=1}^n f_{i'}$$

に対するカーネル行列は

$$\bar{K} = H K H$$

で与えられる

## ■ 数学演習: これを証明せよ

- ヒント: 中心化を行列で表現する

$$F = (f_1, \dots, f_n) \quad \bar{F} = (\bar{f}_1, \dots, \bar{f}_n)$$

$$H = I_n - \frac{1}{n} \mathbf{1}_{n \times n}$$

$I$ : 単位行列

$\mathbf{1}$ : 全てが1の行列

$$K = F^\top F$$

$$\bar{K} = \bar{F}^\top \bar{F}$$

# カーネル主成分分析

30

1. カーネル関数  $K(x, x')$  を選ぶ.

$$H = I_n - \frac{1}{n} \mathbf{1}_{n \times n}$$

2. 特徴の中心化を(暗に)行なう:

$I$ : 単位行列

$$K \leftarrow H K H$$

$\mathbf{1}$ : 全てが1のベクトル・行列

3. (双対の) 固有値問題を解く:

$$K_{i,j} = K(x_i, x_j)$$

$$K \alpha = \lambda \alpha$$

$$\lambda_1 \geq \dots \geq \lambda_n$$

$$\|\alpha_i\| = 1$$

4. 入力  $x$  の特徴空間内での埋め込み結果:

$$\Lambda^{-\frac{1}{2}} A^\top k$$

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_m)$$

元のデータ  $\{x_i\}_{i=1}^n$  を埋め込む

$$A = (\alpha_1, \dots, \alpha_m)^\top$$


ときは

$$\Lambda^{-\frac{1}{2}} A^\top K$$


$$k_i = K(x_i, x)$$

## ■ ringnorm data (20次元)

線形主成分分析




カーネル主成分分析  
(ガウスカーネル)



$c = 5$

$$K(x, x') = \exp \left( -\|x - x'\|^2 / c^2 \right)$$

# カーネル主成分分析の問題点 32



$$K(\boldsymbol{x}, \boldsymbol{x}') = \exp \left( -\|\boldsymbol{x} - \boldsymbol{x}'\|^2 / c^2 \right)$$

- カーネルの選び方で大きく結果が変わる.
- 特徴空間の次元が高いと元の空間に戻せない.

- 非線形変換を指定するのではなく, 非線形変換後の標本の内積を**カーネル関数**で指定する
- カーネル関数が簡単に計算できる限りは, カーネル主成分分析の計算量は**特徴空間の次元数に依存しない**
- **ガウスカーネル**を用いると, 特徴空間の次元数は**無限大**
- カーネルの選び方(=非線形変換の選び方)が難しい

# 講義の流れ



## 1. カーネル主成分分析(13章)

- A) 双対空間における直接的計算法
- B) カーネルを用いた間接的計算法
- C) カーネルについて

## 2. ラプラス固有写像(13章)

## ■ 二つのカーネル関数

$$K(x, x') = f^\top f'$$

$$L(x, x') = g^\top g'$$

に対して、以下もカーネル関数である：

1. 定数倍： $\alpha K(x, x')$      $\alpha > 0$

2. 和： $K(x, x') + L(x, x')$

3. 積： $K(x, x')L(x, x')$

## ■ 数学演習：これらを証明せよ



■ ノルム:


$$\|f\| = \sqrt{K(x, x)}$$

■ 距離:

$$\|f - f'\|^2 = K(x, x) - 2K(x, x') + K(x', x')$$

■ 角度:  $f^\top f' = \|f\| \|f'\| \cos \theta$  より

$$\cos \theta = \frac{K(x, x')}{\sqrt{K(x, x)K(x', x')}}}$$




# ガウスカーネルの性質

38

$$K(\boldsymbol{x}, \boldsymbol{x}') = \exp(-\|\boldsymbol{x} - \boldsymbol{x}'\|^2 / c^2) \quad c > 0$$

■ ガウスカーネルに対しては,

- $\|f\| = 1$
- $\|f - f'\|^2 = 2 - 2K(\boldsymbol{x}, \boldsymbol{x}')$
- $\cos \theta = K(\boldsymbol{x}, \boldsymbol{x}')$



$$f^\top f' = K(x, x')$$

- 特徴空間での内積をカーネル関数を用いて効率良く計算できる.
- 内積だけで表現できる線形アルゴリズムは、カーネル化できる！
  - 次元削減：PCA, LPP, FDAなど
  - クラスタリング：k-平均法など
  - 関数近似：線形回帰，線形サポートベクトルマシン，フィッシャー線形判別分析など

$$x^\top x' \rightarrow K(x, x')$$


# 講義の流れ




1. カーネル主成分分析(13章)
2. ラプラス固有写像(13章)

# 局所性保存射影 (LPP: Locality Preserving Projection)

- **考え方**: データの **局所的な構造** をできるだけ保存したい



もとの空間で近くにある  
標本を近くに埋め込む



# 類似度行列

## ■ 類似度行列 $W$ :

- $x_i$  と  $x_{i'}$  が近い:  $W_{i,i'} \rightarrow 1$
- $x_i$  と  $x_{i'}$  が遠い:  $W_{i,i'} \rightarrow 0$

$$W_{i,i'} = W_{i',i}$$

$$\exists W^{-1}$$

## ■ 例:

- 距離ベース:

$$W_{i,i'} = \exp \left( -\frac{\|x_i - x_{i'}\|^2}{2t^2} \right)$$

$$t > 0$$

- 近傍ベース:

$$W_{i,i'} = \begin{cases} 1 & \text{if } x_i \in kNN(x_{i'}) \\ & \text{or } x_{i'} \in kNN(x_i) \\ 0 & \text{otherwise} \end{cases}$$

$$k \in \mathbb{N}$$

# 局所性保存射影の規準

■ もとの空間で近くにある標本を近くに埋め込む:

$$T_{\text{LPP}} = \operatorname{argmin}_{T \in \mathbb{R}^{m \times d}} \sum_{i,i'=1}^n W_{i,i'} \|Tx_i - Tx_{i'}\|^2$$


$$\text{subject to } TXDX^\top T^\top = I_m$$

解が縮退しないように  
適当な拘束条件をつける

$$X = (x_1, \dots, x_n)$$

$$D = \operatorname{diag} \left( \sum_{i'=1}^n W_{i,i'} \right)$$

$I$ : 単位行列



# 局所性保存射影の解の求め方 44

$$\mathbf{T}_{\text{LPP}} = \underset{\mathbf{T} \in \mathbb{R}^{m \times d}}{\operatorname{argmin}} \operatorname{tr} \left( \mathbf{T} \mathbf{X} \mathbf{L} \mathbf{X}^\top \mathbf{T}^\top \right)$$

$$\text{subject to } \mathbf{T} \mathbf{X} \mathbf{D} \mathbf{X}^\top \mathbf{T}^\top = \mathbf{I}_m$$

1. 一般化固有値問題を解く:

$$\mathbf{L} = \mathbf{D} - \mathbf{W}$$

$$\mathbf{X} \mathbf{L} \mathbf{X}^\top \boldsymbol{\xi} = \lambda \mathbf{X} \mathbf{D} \mathbf{X}^\top \boldsymbol{\xi}$$

$$\mathbf{D} = \operatorname{diag} \left( \sum_{i'=1}^n W_{i,i'} \right)$$

$$\lambda_1 \geq \cdots \geq \lambda_d \quad \boldsymbol{\xi}_j^\top \mathbf{X} \mathbf{D} \mathbf{X}^\top \boldsymbol{\xi}_j = 1$$

$$\mathbf{X} = (\mathbf{x}_1, \dots, \mathbf{x}_n)$$

2. 下位  $m$  個の一般化固有ベクトルを並べる:

$$\mathbf{T}_{\text{LPP}} = (\boldsymbol{\xi}_d, \boldsymbol{\xi}_{d-1}, \dots, \boldsymbol{\xi}_{d-m+1})^\top$$



# 局所性保存射影の解の求め方 45

## ■ 局所性保存射影:

$$T_{\text{LPP}} = \operatorname{argmin}_{T \in \mathbb{R}^{m \times d}} \operatorname{tr} \left( T X L X^{\top} T^{\top} \right)$$

$$\text{subject to } T X D X^{\top} T^{\top} = I_m$$

- 埋め込んだデータ:  $\Psi^{\top} = T_{\text{LPP}} X$

## ■ 暗黙のうちに各標本の次元 $d$ が大きい場合を考える

- 埋め込み先を直接求める

## ■ 一般化固有値問題 $L\psi = \gamma D\psi$ の解を小さい順に並べたものが解となる

- 固有値問題  $L\psi = \gamma D\psi$  の最小固有値  $\gamma_n$  は 0 であり, その固有ベクトルは 1 (定数).

証明は宿題

1 : 全てが1のベクトル

- よって, 最小固有値に対応する固有ベクトルは無視する. このとき, 埋め込み先は

$$\Psi^\top = (\psi_{n-1}, \psi_{n-2}, \dots, \psi_{n-m})^\top$$

$$\gamma_1 \geq \dots \geq \gamma_n \quad \psi_i^\top D \psi_i = 1$$


- 類似度行列  $W$  が **スパース** の時は  $L$  と  $D$  もスパースになり, 固有値問題が効率良く解ける

# 実行例

47

もとの3次元データ

次元削減後の2次元データ



# ラプラス固有写像：まとめ

48

- 局所性保存射影のカーネル化
- 手持ちの訓練標本を埋め込むときは、固有値問題が単純化できる
- 類似度行列がスパースの時、**スパース固有値問題**になり効率良く解ける

# 講義の流れ



1. カーネル主成分分析(13章)
2. ラプラス固有写像(13章)

- **次元の呪い**: 高次元データは非常に扱いにくい
- **次元削減**: データの特徴を残しつつ次元を削減
- **カーネル・トリック**:
  - 線形次元削減アルゴリズムを手軽に非線形化
  - 大域的最適解が求まる
  - 回帰, 分類, クラスタリングなどにも適用可能
  - カーネルの選択が難しい

# 次回の予告



- ニューラルネットワークを用いた非線形次元削減

- 固有値問題  $L\psi = \gamma D\psi$  の最小固有値  $\gamma_n$  は 0, 対応する固有ベクトルは  $\mathbf{1}$  であることを示せ

$$L = D - W$$

$$D = \text{diag} \left( \sum_{i'=1}^n W_{i,i'} \right)$$

■ ヒント:

$\mathbf{1}$  : 全てが1のベクトル

- $L$  が半正定値行列 (全ての固有値が非負), つまり任意の  $\alpha$  で  $\alpha^\top L \alpha \geq 0$  であることを示す.
- $\mathbf{1}$  が固有値ゼロに対応する固有ベクトルであることを示す



- 最近傍類似度に対するラプラス固有写像を実装せよ

$$W_{i,i'} = \begin{cases} 1 & \text{if } \mathbf{x}_i \in kNN(\mathbf{x}_{i'}) \\ & \text{or } \mathbf{x}_{i'} \in kNN(\mathbf{x}_i) \\ 0 & \text{otherwise} \end{cases}$$

```
clear all; rand('state',0); randn('state',0);  
n=1000; a=3*pi*rand(n,1);  
x=[a.*cos(a) 30*rand(n,1) a.*sin(a)]; z=LapEig(x,2);  
figure(1); clf; hold on; view([15 10]);  
scatter3(x(:,1),x(:,2),x(:,3),40,a,'o');  
figure(2); clf; hold on;  
scatter(z(:,2),z(:,1),40,a,'o');
```

LapEig.m  
を実装せよ