

# 先端人工知能論 生成モデル

2017.10.17

佐藤一誠

# もくじ

- 復習(生成モデル,変分推論の基礎)
- 変分法
- 変分オートエンコーダー

# 授業で使う記法

$x_i$  :  $i$ 番目の観測データ ( $i=1, \dots, n$ )

$x_{i,d}$  :  $x_i$  の $d$ 次元要素 ( $d=1, \dots, D$ )

$x_{1:n}$  :  $n$ 個の観測データ

$z_i$  :  $i$ 番目の潜在変数 ( $i=1, \dots, n$ )

$z_{i,k}$  :  $z_i$  の $k$ 次元要素 ( $k=1, \dots, K$ )

$z_{1:n}$  :  $n$ 個の潜在変数

$p(x|\theta)$  :  $\theta$ をパラメータとする確率分布

$p_\theta(x)$ と書くこともある

$x = 1$  となる確率を $\pi$ ,  $x = 0$  となる確率を $1-\pi$ とする.  
二値確率変数 $x$ が, 確率分布

$$\text{Be}(x | \pi) = \pi^x (1 - \pi)^{1-x}$$

に従うとき,  $x$  は $\pi$ をパラメータとする  
ベルヌーイ分布に従うという

実数値確率変数 $x$ が, 確率密度関数

$$N(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}(x - \mu)^2\right)$$

をもつとき,  $x$ は平均 $\mu$ , 分散 $\sigma^2$ をパラメータ  
とする正規分布に従うという

# 識別モデルと生成モデルの学習

識別モデル

学習データ  
 $\{(y_i, x_i)\}_{i=1}^n$



$$y_i = \underline{f_\theta(x_i)}$$

関数を学習

生成モデル

学習データ:  
 $\{x_i\}_{i=1}^n$



$$x_i = \underline{f_\theta(z_i)}$$

関数及び潜在変数を学習

# 識別モデル

# 学習

生成モデルは統計モデルによって記述されるため、実際には

$$x_i \sim \underline{p_\theta}(x \mid \underline{z_i})$$

確率分布及び潜在変数を学習

生..

学習データ:

$$\{x_i\}_{i=1}^n$$

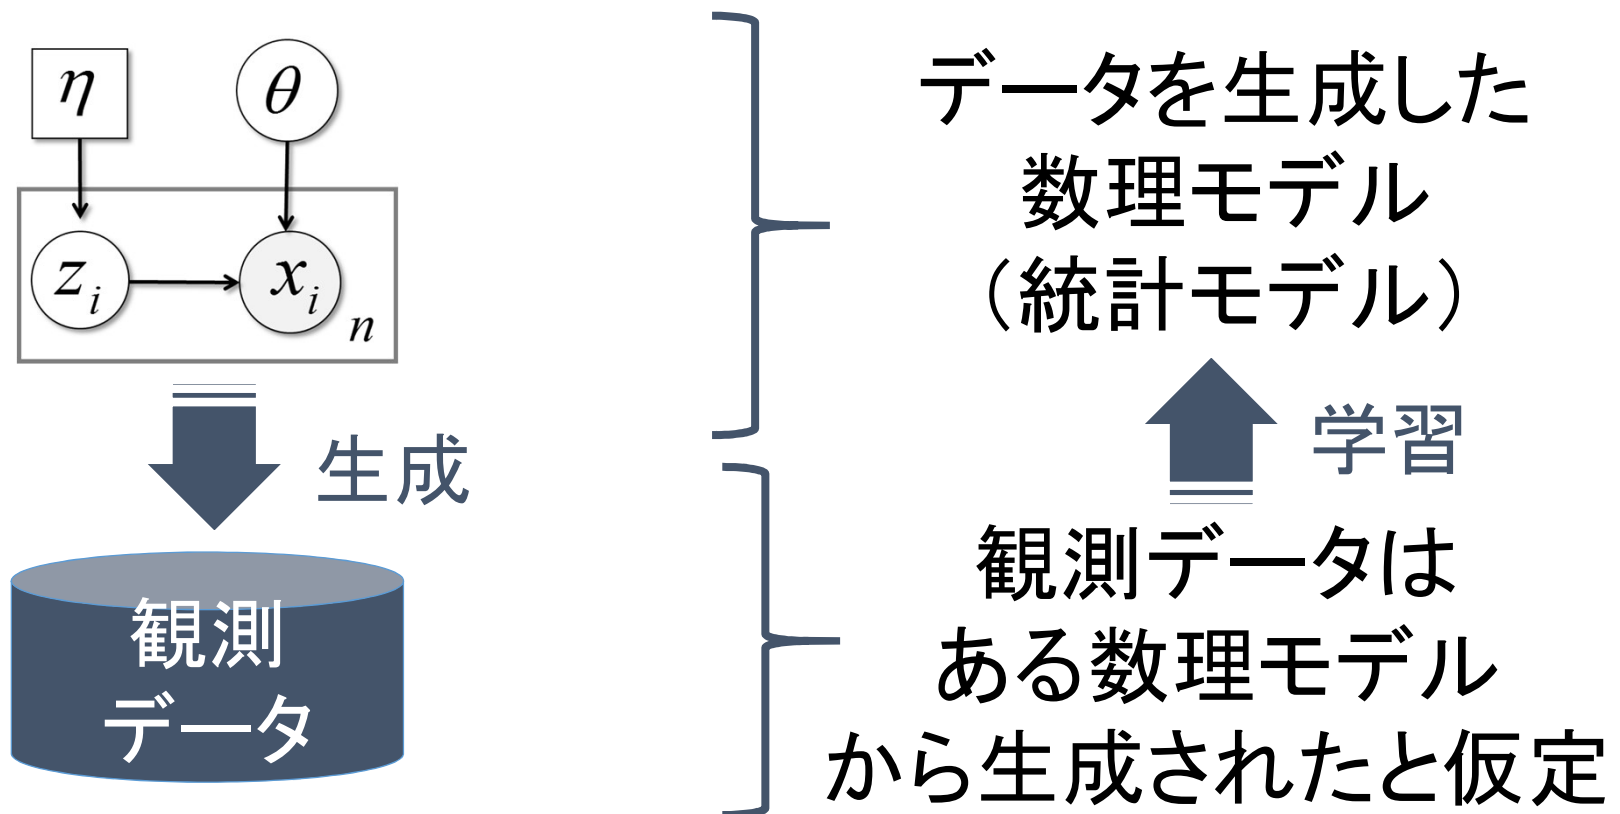


$$x_i = \underline{f_\theta}(\underline{z_i})$$

関数及び潜在変数を学習

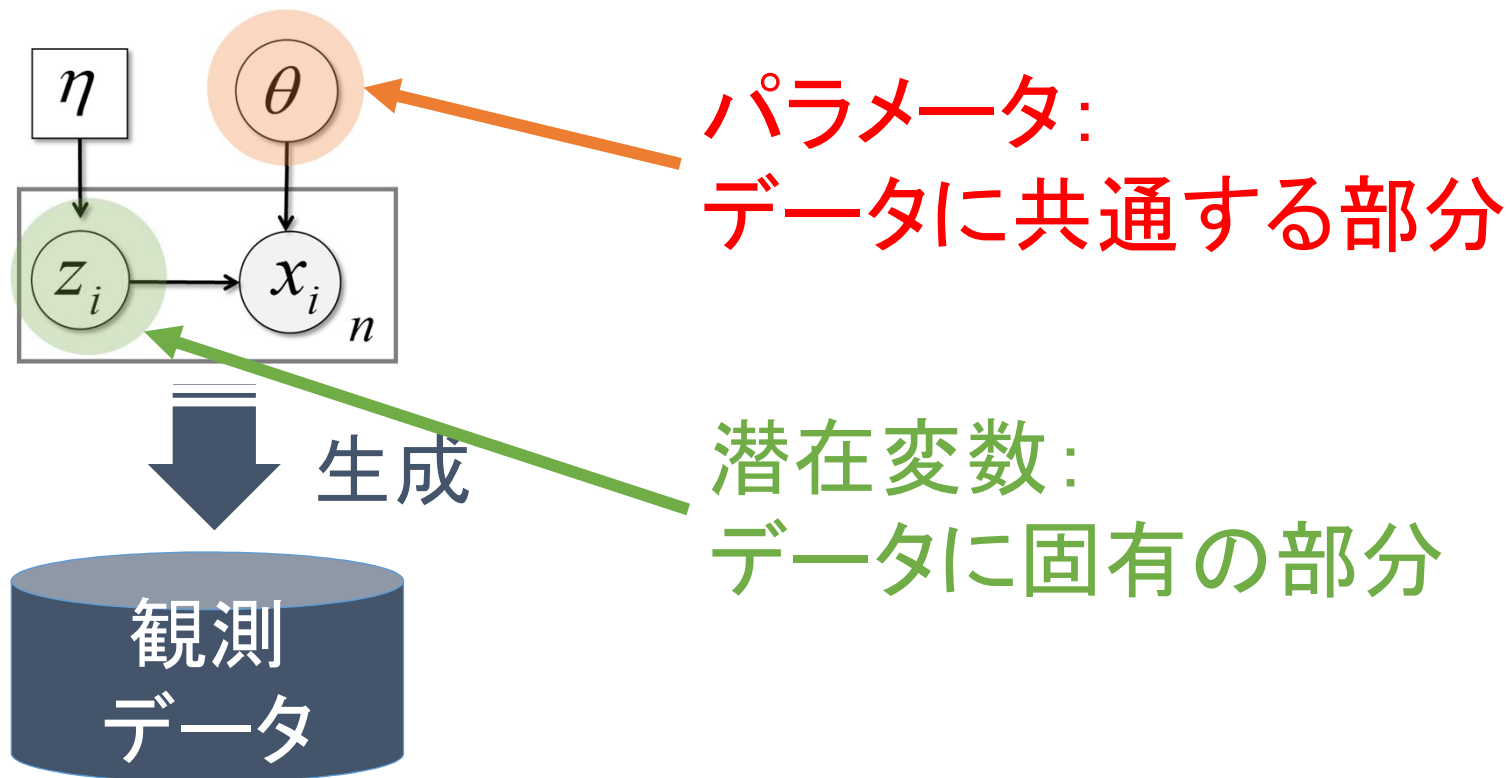
# 生成モデル

データの生成過程を数理モデルにより表現したもの



# 生成モデル

データの生成過程を数理モデルにより表現したもの





# 変分推論

(Variational inference)

$$\underline{\log p_{\theta}(x_i)}$$

$$= \log \int p_{\theta}(x_i, z_i) dz_i$$

何ら仮定をおかずに  
確率分布を導入

$$= \log \int \boxed{q(z_i)} \frac{p_{\theta}(x_i, z_i)}{\boxed{q(z_i)}} dz_i$$

$$\underline{\log p_{\theta}(x_i)}$$

$$= \log \int p_{\theta}(x_i, z_i) dz_i$$

何ら仮定をおかずに  
確率分布を導入

$$= \log \int q(z_i) \frac{p_{\theta}(x_i, z_i)}{q(z_i)} dz_i$$

$$= \log E_{q(z_i)} \left[ \frac{p_{\theta}(x_i, z_i)}{q(z_i)} \right]$$

$$\underline{\log p_{\theta}(x_i)}$$

$$= \log \int p_{\theta}(x_i, z_i) dz_i$$

何ら仮定をおかずに  
確率分布を導入

$$= \log \int q(z_i) \frac{p_{\theta}(x_i, z_i)}{q(z_i)} dz_i$$

$$= \log E_{q(z_i)} \left[ \frac{p_{\theta}(x_i, z_i)}{q(z_i)} \right]$$


$$\geq E_{q(z_i)} \left[ \log \frac{p_{\theta}(x_i, z_i)}{q(z_i)} \right]$$

# 凸関数

- 任意の  $x, x' \in \mathcal{X}$  任意の  $\theta \in [0, 1]$  に対して,

$$f((1-\theta)x + \theta x') \leq (1-\theta)f(x) + \theta f(x')$$

ならば,  $f$  を凸関数(convex function)とよぶ




# Jensenの不等式

$h(x)$  を凸関数とする.  
確率変数 $X$ に対して

$$h(E[X]) \leq E[h(X)]$$

が成り立つ.



$$\underline{\log p_{\theta}(x_i)}$$

$$= \log \int p_{\theta}(x_i, z_i) dz_i$$

何ら仮定をおかずに  
確率分布を導入

$$= \log \int q(z_i) \frac{p_{\theta}(x_i, z_i)}{q(z_i)} dz_i$$

$$= \log E_{q(z_i)} \left[ \frac{p_{\theta}(x_i, z_i)}{q(z_i)} \right]$$

$$\geq E_{q(z_i)} \left[ \log \frac{p_{\theta}(x_i, z_i)}{q(z_i)} \right]$$

$$\underline{\log p_{\theta}(x_i)}$$

$$= \log \int p_{\theta}(x_i, z_i) dz_i$$

何ら仮定をおかずに  
確率分布を導入

$$= \log \int \boxed{q(z_i)} \frac{p_{\theta}(x_i, z_i)}{\boxed{q(z_i)}} dz_i$$

$$\geq \int q(z_i) \log \frac{p_{\theta}(x_i, z_i)}{q(z_i)} dz_i$$



$$\log p_{\theta}(x_i)$$

$$\geq \int q(z_i) \log \frac{p_{\theta}(x_i, z_i)}{q(z_i)} dz_i$$

$$\equiv L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

変分下限最大化へ帰着


$$(q^*(z_i), \theta^*) = \arg \max_{q(z_i), \theta} L[q(z_i), \theta; x_i]$$

# 練習問題 データが複数ある場合

$\log p_{\theta}(x_{1:n})$  の変分下限が

$$\log p_{\theta}(x_{1:n}) \geq \sum_{i=1}^n L[q(z_i), \theta; x_i]$$

となることを示せ



$$\log p_{\theta}(x_{1:n})$$

$$= \log \int p_{\theta}(x_{1:n}, z_{1:n}) dz_{1:n}$$

何ら仮定をおかずに  
確率分布を導入

$$= \log \int q(z_{1:n}) \frac{p_{\theta}(x_{1:n}, z_{1:n})}{q(z_{1:n})} dz_{1:n}$$

$$\geq \int q(z_{1:n}) \log \frac{p_{\theta}(x_{1:n}, z_{1:n})}{q(z_{1:n})} dz_{1:n}$$

$$= \int q(z_{1:n}) (\log p_{\theta}(x_{1:n}, z_{1:n}) - \log q(z_{1:n})) dz_{1:n}$$

$$\int q(z_{1:n}) \log p_{\theta}(x_{1:n}, z_{1:n}) dz_{1:n}$$

$$= \int \prod_{i=1}^n q(z_i) \log \prod_{i=1}^n p_{\theta}(x_i, z_i) dz_1 dz_2 \cdots dz_n$$

$$= \int \prod_{i=1}^n q(z_i) \sum_{i=1}^n \log p_{\theta}(x_i, z_i) dz_1 dz_2 \cdots dz_n$$

$$\begin{aligned} & \int q(z_1)q(z_2)(\log p_\theta(x_1, z_1) + \log p_\theta(x_2, z_2))dz_1dz_2 \\ &= \int q(z_1)q(z_2)\log p_\theta(x_1, z_1)dz_1dz_2 \\ &\quad + \int q(z_1)q(z_2)\log p_\theta(x_2, z_2)dz_1dz_2 \\ &= \int q(z_1)\log p_\theta(x_1, z_1)dz_1 \int q(z_2)dz_2 \\ &\quad + \int q(z_2)\log p_\theta(x_2, z_2)dz_2 \int q(z_1)dz_1 \end{aligned}$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

変分下限最大化へ帰着

$$(q^*(z_{1:n}), \theta^*) = \arg \max_{q(z_{1:n}), \theta} \sum_{i=1}^n L[q(z_i), \theta; x_i]$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = \arg \max_{q(z_i)} L[q(z_i), \theta_{t-1}; x_i]$$

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = \arg \max_{q(z_i)} L[q(z_i), \theta_{t-1}; x_i]$$

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$



目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

確率分布の最適化

$$q_t(z_i) = \arg \max_{q(z_i)} L[q(z_i), \theta_{t-1}; x_i]$$

➡ 変分法で解ける

# 变分法

# 汎関数

## 関数を入力とする関数

例

$$L[f(x)] = \int_0^{\pi} f(x) dx$$

$f(x)=\sin(x)$ ,  $\cos(x)$ を入力すると  
 $L$ の値が変わる

# 変分法

## 微分法

目的: 関数 $f(x)$  の極値を求めたい

$$\frac{df(x)}{dx} = 0 \text{ となる } x \text{ を求める}$$

## 変分法

目的: 汎関数 $L[f(x)]$  の極値を求めたい

$$\frac{\delta L[f]}{\delta f} = 0 \text{ となる関数 } f(x) \text{ を求める}$$

# 変分法

汎関数を以下のように定義する

$$L[q(x)] = \int f(x, q) dx$$

例 エントロピー

$$L[q(x)] = \int -q(x) \log q(x) dx$$

汎関数 $L[q(x)]$  の極値を与える $q(x)$ は以下の  
オイラー・ラグランジュ方程式を解けばよい

$$\frac{\partial f(x, q)}{\partial q(x)} = 0$$

目的関数

$$\underline{\log p_{\theta}(x_i)}$$

$$\geq \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv L[q(z_i), \theta; x_i]$$

この部分を $q(z_i)$ で  
微分=0を解けば良い

確率分布の最適化

$$q_t(z_i) = \arg \max_{q(z_i)} L[q(z_i), \theta_t; x_i]$$

➡ 変分法で解ける(演習)

目的関数

$$\underline{\log p_{\theta}(x_i)}$$

$$\geq \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv L[q(z_i), \theta; x_i]$$

この部分を $q(z_i)$ で  
微分=0を解けば良い

確率分布の最適化

$$q_t(z_i) = p_{\theta_t}(z_i | x_i)$$

事後分布

# 導出

$\lambda$ を定数として, 以下の汎関数の極値を求める

$$\int q(z_i) \log \frac{p_\theta(x_i | z_i) p(z_i)}{q(z_i)} dz_i + \lambda \left( 1 - \int q(z_i) dz_i \right)$$

制約付き最適化

$$\partial_{q(z_i)} \left( q(z_i) \log \frac{p_\theta(x_i | z_i) p(z_i)}{q(z_i)} - \lambda q(z_i) \right) = 0$$

$$\Leftrightarrow \log \frac{p_\theta(x_i | z_i) p(z_i)}{q(z_i)} - 1 - \lambda = 0$$



# 導出

$\lambda$ を定数として, 以下の汎関数の極値を求める

$$\int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i + \lambda \left( 1 - \int q(z_i) dz_i \right)$$

制約付き最適化

$$q_t(z_i) = e^{-\lambda-1} p_{\theta_t}(x_i | z_i) p(z_i)$$

$$\int q_t(z_i) dz_i = 1 \text{ より}$$

$$q_t(z_i) = \frac{p_{\theta_t}(x_i | z_i) p(z_i)}{\int p_{\theta_t}(x_i | z_i) p(z_i) dz_i} = p_{\theta_t}(z_i | x_i)$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = \arg \max_{q(z_i)} L[q(z_i), \theta_t; x_i]$$

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = p_{\theta}(z_i | x_i) \quad \text{EMアルゴリズムと呼ばれる}$$

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = p_{\theta}(z_i | x_i)$$


これを求めるのが  
難しい問題 $\Rightarrow$ VAE

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$

# 変分オートエンコーダー

(Variational auto-encoder)

Diederik P Kingma, Max Welling,  
Auto-Encoding Variational Bayes , 2014




# 例. ベルヌーイ多層パーセプトロン

$$x_i \in \{0,1\}^D$$

$$z_i \in R^K$$

$$\theta = \{W_1, W_2, b_1, b_2\}$$



K次元正規分布


$$z_i \sim N(0, I_K)$$

Element-wise シグモイド関数

$$\pi_i = \text{sigmoid}(W_2 \tanh(W_1 z_i + b_1) + b_2)$$

Element-wise ベルヌーイ分布

$$x_i \sim \text{Be}(\pi_i)$$






# 例. 半教師あり生成モデル

$$z_{2,i} \sim N(0, I_K)$$

$$y_i \sim \text{Cat}(\pi)$$

$$z_{1,i} \sim p_{\theta}(z_1 | y_i, z_{2,i})$$

$$x_i \sim p_{\theta}(x | z_{1,i})$$



## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = p_{\theta}(z_i | x_i)$$

これを求めるのが  
難しい問題 $\Rightarrow$ VAE

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$

## 目的関数

$$\log p_{\theta}(x_{1:n})$$

$$\geq \sum_{i=1}^n \int q(z_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q(z_i)} dz_i$$

$$\equiv \sum_{i=1}^n L[q(z_i), \theta; x_i] \text{ 変分下限などと呼ばれる}$$

交互最適化アルゴリズム

$$q_t(z_i) = \arg \max_{q(z_i)} L[q(z_i), \theta_t; x_i]$$

解けるクラスに限定

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[q_t(z_i), \theta; x_i]$$

# 変分近似事後分布

$$\begin{aligned}
 q(z_i) &= q_\phi(z_i | x_i) = \prod_{k=1}^K q_\phi(z_{i,k} | x_i) \\
 &= \prod_{k=1}^K N(z_{i,k} | \mu_k(x_i), \sigma_k^2(x_i))
 \end{aligned}$$

$$\mu_k(x_i) = \tanh(W_2^\mu \tanh(W_1^\mu x_i + b_1^\mu) + b_2^\mu)$$

$$\sigma_k^2(x_i) = \exp(W_2^\sigma \tanh(W_1^\sigma x_i + b_1^\sigma) + b_2^\sigma)$$

$$\phi = \{W_1^\mu, W_2^\sigma, W_1^\mu, W_2^\mu, b_1^\mu, b_2^\mu, b_1^\sigma, b_2^\sigma\}$$

$$\underline{\log p_{\theta}(x_i)}$$

$$\geq \int q_{\phi}(z_i | x_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q_{\phi}(z_i | x_i)} dz_i$$

$$\equiv L[\phi, \theta; x_i]$$

交互最適化アルゴリズム

$$\phi_t = \arg \max_{\phi} \sum_{i=1}^n L[\phi, \theta_t; x_i]$$

$$\theta_t = \arg \max_{\theta} \sum_{i=1}^n L[\phi_t, \theta; x_i]$$

$$\underline{\log p_{\theta}(x_i)}$$

$$\geq \int q_{\phi}(z_i | x_i) \log \frac{p_{\theta}(x_i | z_i) p(z_i)}{q_{\phi}(z_i | x_i)} dz_i$$

$$\equiv L[\phi, \theta; x_i]$$

交互最適化アルゴリズム(勾配法)

$$\phi_t = \phi_{t-1} + \rho_t \partial_{\phi} \sum_{i=1}^n L[\phi, \theta_t; x_i]$$

$$\theta_t = \theta_{t-1} + \rho_t \partial_{\theta} \sum_{i=1}^n L[\phi_t, \theta; x_i]$$

# 変分下限の分析

$$L[\varphi, \theta; x_i] =$$

$$\int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

$$- \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

# 変分下限の分析

$$L[\varphi, \theta; x_i] = \text{解析的に解けない}$$

$$\int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

$$- \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

KL情報量(Kullback-liber divergence)  
解析的に積分計算可能



# 変分下限の分析

$$q_{\phi}(z_i | x_i) = \prod_{k=1}^K N(z_{i,k} | \mu_{i,k}, \sigma_{i,k}^2)$$

$$p(z_i) = \prod_{k=1}^K N(z_{i,k} | 0, 1)$$

$$-\int q_{\phi}(z_i | x_i) \log \frac{q_{\phi}(z_i | x_i)}{p(z_i)} dz_i$$

$$= \frac{1}{2} \sum_{k=1}^K (1 + \log \sigma_{i,k}^2(x_i) - \mu_{i,k}^2(x_i) - \sigma_{i,k}^2(x_i))$$

# 変分下限の分析

$$L[\varphi, \theta; x_i] =$$

解析的に解けない

$$\int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

$$- \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

KL情報量(Kullback-liber divergence)  
解析的に積分計算可能

# 変分下限の分析

$$L[\varphi, \theta; x_i] =$$

<積分計算できない場合の対処法>

$$\int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

サンプリングによる近似

を使えばいいのでは？

$$\int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

KL情報量(Kullback-liber divergence)

解析的に積分計算可能

# 変分下限の近似

解析的に解けない

$$\int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

$$\approx \frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

$$z_i^{(s)} \sim q_{\varphi}(z_i | x_i)$$

# 変分下限の近似

$$L[\varphi, \theta; x_i] \approx$$

$$\frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

$$- \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

# 変分下限の近似

$L[\varphi, \theta; x_i] \approx$   
 <積分計算できない場合の対処法>

$$\frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

サンプリングによる近似

で問題は解決するのか？

$$= \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

# 求めたかったものは勾配

$$\partial_{\varphi} L[\varphi, \theta; x_i] =$$

$$\partial_{\varphi} \int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

$$\partial_{\varphi} - \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

# 変分下限の近似

$$L[\varphi, \theta; x_i] \approx \quad \varphi \text{に関する勾配が計算できない}$$

$$\frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

$$-\int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$



Reparameterization trick

# 正規分布からのサンプリング

$$E_{z \sim N(\mu, \sigma^2)}[f(z)] \approx \frac{1}{S} \sum_{s=1}^S f(z^{(s)})$$

$$z_i^{(s)} \sim N(\mu, \sigma^2)$$

$$\begin{cases} z_i^{(s)} = \mu + \sigma \xi^{(s)} \\ \xi^{(s)} \sim N(0, 1) \end{cases}$$

## Reparameterization trick

$$E_{z \sim N(\mu, \sigma^2)}[f(z)] \approx \frac{1}{S} \sum_{s=1}^S f(\mu + \sigma \xi^{(s)})$$

$$\begin{cases} z_i^{(s)} \sim N(\mu, \sigma^2) \\ \xi^{(s)} \sim N(0, 1) \end{cases} \quad z_i^{(s)} = \mu + \sigma \xi^{(s)}$$

# 変分下限の近似

$$L[\varphi, \theta; x_i] \approx$$

$$\frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i \mid z_i^{(s)})$$

$$- \int q_{\varphi}(z_i \mid x_i) \log \frac{q_{\varphi}(z_i \mid x_i)}{p(z_i)} dz_i$$

# 変分下限の近似

$$L[\varphi, \theta; x_i] \approx$$

$$\frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i \mid z_i^{(s)})$$

$$z_{i,k}^{(s)} = \mu_k(x_i) + \sigma_k(x_i) \xi_{i,k}^{(s)}$$

$$\xi_{i,k}^{(s)} \sim N(0,1)$$

## 変分下限の近似

$$\frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

$$= x_{i,k} \log \pi_{i,k}^{(s)} + (1 - x_{i,k}) \log(1 - \pi_{i,k}^{(s)})$$

$$\pi_i^{(s)} = \text{sigmoid}(W_2 \tanh(W_1 z_i^{(s)} + b_1) + b_2)$$

# ベルヌーイ多層パーセプトロンの変分下限 <sup>63</sup>

$$L[\varphi, \theta; x_i] \approx \frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

$$x_{i,k} \log \pi_{i,k}^{(s)} + (1 - x_{i,k}) \log(1 - \pi_{i,k}^{(s)})$$

$$- \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

$$\frac{1}{2} \sum_{k=1}^K (1 + \log \sigma_k^2(x_i) - \mu_k^2(x_i) - \sigma_k^2(x_i))$$

## 交互最適化アルゴリズム(勾配法)

$$\phi_t = \phi_{t-1} + \rho_t \partial_{\phi} \sum_{i=1}^n L[\phi, \theta_t; x_i]$$

$$\theta_t = \theta_{t-1} + \rho_t \partial_{\theta} \sum_{i=1}^n L[\phi_t, \theta; x_i]$$

nが大きい

⇒ミニバッチを用いる（確率的最適化）

勾配の計算が難しい

⇒自動微分を用いる



# アルゴリズムの意味を考える

# 変分下限の分析: $\theta$ を求める視点

$$\arg \max_{\theta} L[\varphi, \theta; x_i]$$

$$= \arg \max_{\theta} \int q_{\varphi}(z_i | x_i) \log p_{\theta}(x_i | z_i) dz_i$$

$$- \int q_{\varphi}(z_i | x_i) \log \frac{q_{\varphi}(z_i | x_i)}{p(z_i)} dz_i$$

# 変分下限の分析: $\theta$ を求める視点

$$\arg \max_{\theta} L[\varphi, \theta; x_i]$$

$$\approx \arg \max_{\theta} \frac{1}{S} \sum_{s=1}^S \log p_{\theta}(x_i | z_i^{(s)})$$

$$z_i^{(s)} \sim q_{\varphi}(z_i | x_i)$$

# 変分下限の分析: $\theta$ を求める視点

$$\arg \max_{\theta} L[\varphi, \theta; x_i]$$

$$\approx \arg \min_{\theta} \frac{1}{S} \sum_{s=1}^S -\log p_{\theta}(x_i | z_i^{(s)})$$


$$z_i^{(s)} \sim q_{\varphi}(z_i | x_i)$$

# 変分下限の分析: $\theta$ を求める視点

$$\arg \max_{\theta} L[\varphi, \theta; x_i]$$

デコードエラー

$$\approx \arg \min_{\theta} \frac{1}{S} \sum_{s=1}^S -\log p_{\theta}(x_i | z_i^{(s)})$$



$$z_i^{(s)} \sim q_{\varphi}(z_i | x_i)$$

エンコード

変分オートエンコーダ  
と呼ばれる